



本科生毕业论文（设计）

题目：面向图像生成与理解统一模型的
下游微调方法设计

姓 名 李 英 骏

学 号 21307099

院 系 计算机学院

专 业 计算机科学与技术

指导教师 魏朋旭 (副教授)

2025 年 4 月 25 日

面向图像生成与理解统一模型的

下游微调方法设计

Design of Downstream Fine-Tuning Methods for

Unified Image Generation and Understanding Models

姓 名	李 英 骏
学 号	21307099
院 系	计算机学院
专 业	计算机科学与技术
指导教师	魏朋旭 (副教授)

2025 年 4 月 25 日

学术诚信声明

本人郑重声明：所呈交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文（设计）不包含任何其他个人或集体已经发表或撰写过的作品成果。对本论文（设计）的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本论文（设计）的知识产权归属于培养单位。本人完全意识到本声明的法律结果由本人承担。

作者签名：

日 期： 年 月 日

【摘 要】

本文针对统一图文理解与生成模型 JanusPro 7B，提出一种创新的两阶段微调框架以提升科学问答性能。第一阶段自动化合成高质量推理链（CoT）数据以增强基础推理能力。第二阶段利用原始及合成数据，通过我们改进的 GRPO 强化学习算法进行指令微调。该优化 GRPO 算法针对标准 RL 的局限性，引入了 1) 词元级优化策略（如非对称裁剪）提升训练稳定性与探索性，2) 与问题难度自适应的动态奖励机制（结合长度、格式等多维度），以及 3) 基于大模型辅助的推理可信度评估体系，有效提升了推理可信度。在 TQA 数据集上的实验表明，该框架将模型准确率从 62.0% 提升至 83.7% (+21.7 pts)，VQA 再验证率从 32% 大幅提升至 57% (+25 pts)，同时显著改善生成质量 FID (-5.66) 和解释合理性 (+2.6)。本研究不仅验证了统一架构的潜力，更为模型强化对齐提供了包含数据合成、算法改进和评估优化的完整解决方案，尤其适用于缺少高质量标注数据集的垂直领域。

关键词： 多模态模型，统一架构，图像生成，图像理解，有监督微调，GRPO，数据合成，推理链，强化学习，科学问答，JanusPro

[ABSTRACT]

Focusing on the JanusPro 7B unified text-image understanding and generation model, this paper proposes an innovative two-stage fine-tuning framework to enhance performance on scientific question answering tasks. The first stage automatically synthesizes high-quality Chain-of-Thought (CoT) data to bolster foundational reasoning capabilities. The second stage utilizes original and synthesized data for instruction fine-tuning via our improved GRPO reinforcement learning algorithm. Addressing the limitations of standard RL, this optimized GRPO algorithm introduces: 1) token-level optimization strategies (e.g., asymmetric clipping) to improve training stability and exploration; 2) a dynamic reward mechanism adaptive to question difficulty (considering dimensions like length and format); and 3) a reasoning credibility assessment system assisted by large models, effectively enhancing reasoning faithfulness. Experiments on the TQA dataset show that the framework increases model accuracy from 62.0% to 83.7% (+21.7 pts) and substantially boosts the VQA re-validation rate from 32% to 57% (+25 pts), while significantly improving generation quality (FID score reduced by 5.66) and explanation rationality (+2.6 points). This research not only validates the potential of unified architectures but also provides a complete solution for model reinforcement alignment—encompassing data synthesis, algorithmic improvements, and evaluation optimization—particularly applicable to vertical domains lacking high-quality annotated datasets.

Keywords: Multimodal Models, Unified Architecture, Image Generation, Image Understanding, Two-Stage Fine-tuning, GRPO, Data Synthesis, Reasoning Chain, Reinforcement Learning, Scientific Question Answering, JanusPro

目录

1	绪论	1
1.1	选题背景与意义	1
1.2	研究现状和相关工作	2
1.3	数据集构建的相关工作	7
1.4	目前微调范式的不足	8
1.5	本文主要研究内容与目标	9
1.6	论文工作与创新点	10
1.7	本文的论文结构与章节安排	11
2	相关基础知识和技术	13
2.1	评价指标	13
2.2	Janus Pro 架构分析	14
2.3	多模态模型微调策略	15
2.4	参数微调方法	17
2.5	数据集介绍	18
2.6	本章小结	18
3	强化学习驱动的推理数据合成	19
3.1	GRPO 算法	19
3.2	GRPO 算法优化：增强推理可靠性与训练稳定性	20
3.3	Galore 算法	28
3.4	实验	29
4	基于合成数据有监督微调与强化微调	33
4.1	视觉编码器	33
4.2	图像理解有监督微调 (SFT)	37
4.3	图像生成与理解联合的有监督微调	38
4.4	引入图像生成奖励的 GRPO	40

4.5 实验	41
5 实验	45
5.1 改进 GRPO 与原始算法的性能对比	45
5.2 图像生成与理解统一模型的协同促进效应	46
6 总结与展望	47
参考文献	49
附录 A 提示词	53
A.1 GPT-4o 提示词	53
A.2 数据合成提示词	54
附录 B 更多合成数据	56
致谢	61

插图目录

1.1	二阶段训练流程	9
2.1	JanusPro 模型架构	15
2.2	GRPO 与 PPO 流程对比	17
3.1	阶段 1: GRPO 流程图	20
3.2	难度自适应长度奖励函数。峰值位置随难度 h 移动, 在目标长度 $K(h)$ 处提供最大奖励 (1.0), 并同时惩罚过短和过长的输出。	23
3.3	阶段 1: GRPO 全过程奖励	30
3.4	阶段 1: 四类奖励与方差对比图: (a) 准确率奖励, (b) 准确率方差, (c) 格式奖励, (d) 格式方差, (e) 长度奖励, (f) 长度方差, (g) 推理奖励, (h) 推理方差	31
3.5	阶段 1: 合成的推理输出示例	32
4.1	阶段 2.1: 图像理解有监督微调	37
4.2	阶段 2.2: 图像描述数据的生成与筛选	39
4.3	阶段 2.3: 图像理解有监督微调	39
4.4	阶段 2.4: 图像生成的 GRPO	40
4.5	图像在三个微调阶段的生成效果对比: 上为原始模型, 中为联合 SFT 后, 下为强化微调 GRPO 后	43
5.1	优化 GRPO 与原始 GRPO 的收敛曲线对比	45

表格目录

1.1	在 GenEval 基准上评估文本生成图像能力。“Und.” 和 “Gen.” 分别表示 “理解” 和 “生成”。使用外部预训练扩散模型的模型用 [†] 标注。	2
1.2	在多模态理解基准上与最先进方法的比较。“Und.” 和 “Gen.” 分别表示 “理解” 和 “生成”。使用外部预训练扩散模型的模型用 [†] 标注。 . .	3
3.1	阶段 1: GRPO 超参数设置	30
4.1	阶段 2: SFT 与优化 GRPO 的超参数设置	42
4.2	在 TQA 和 ScienceQA 上三个阶段的性能对比	42
5.1	纯图像生成数据训练后的性能	46
5.2	纯图像理解数据训练后的性能	46

1 绪论

1.1 选题背景与意义

近年来，随着大规模预训练模型在自然语言处理领域取得突破，融合视觉与语言的多模态大模型也迅速兴起^[1]。这些模型能够同时理解图像和文本信息，在图像描述、视觉问答（Visual Question Answering, VQA）等任务上展现出强大的性能。例如，DeepMind 提出的 Flamingo 模型在少量示例的情况下实现了对图像内容的推理^[1]，而微软的 Kosmos-1 则探索了让大语言模型直接感知视觉输入，从而在零样本/少样本设定下完成图文对话和理解任务^[1]。

与此同时，扩散模型等生成模型的发展使得根据文本生成高质量图像成为可能，而视觉自回归模型（Visual Autoregressive Model, VAR）、向量量化变分自编码器（Vector Quantized Variational Autoencoder, VQ-VAE）等模型使得图像生成模型的规模扩展、以及与自回归语言模型的架构统一变得更加可行^[2-3]，此时，如何对齐不同模态的语义成为多模态学习的核心难题。一种直观做法是设计跨模态模型组合：利用独立训练的图像编码器提取视觉特征，再将其输入语言模型以生成文本答案^[4]。这类方法在多模态任务上取得了一定成功，但由于各模态子模型相互独立，缺乏统一的表示空间，模型难以深度融合图像与文本信息，制约了跨模态推理能力的提高。

随着多模态数据规模和应用需求的增长，我们愈加需要一种统一的端到端模型来处理多模态信息，以充分挖掘不同模态之间的语义关联。顺应这一趋势，新一代视觉-语言多模态大模型开始尝试将图像理解与图像生成能力统一于单一模型，既能根据图片对话，又能根据文字生成图像^[5-6]。例如，Janus 模型通过解耦视觉生成与理解编码，实现了基于自回归大语言模型的多模态理解与生成的统一^[5]。这种统一的模型架构使得理解与生成任务更好地相互促进^[5,7-8]：理解能力的提升有助于生成更准确、更可控的图像，而生成能力的增强也反过来验证和完善了对输入信息的理解。

在科学教育领域，特别是科学问答场景中，引入上述统一模型也具有重大意义。一方面，科学问题往往涉及图文并茂的教材资料，需要模型既能读懂图表又能理解文字说明^[9]。例如，Textbook QA (TQA) 数据集包含来自初中科学教材的多模态问题，要求模型处理复杂的文本和图像信息^[9]。另一方面，生成直观的图像有助于解释复杂的科学概念，增强模型回答的说服力^[10]。

因此，研究一个兼具视觉问答推理和图像生成能力的统一多模态模型，不仅顺应了多模态大模型的发展潮流，也对提升人工智能在科学教育场景下的应用价值具有深远意义。通过整合理解与生成能力，模型可以更全面地处理科学问答任务，提供更丰富和直观的答案解释，促进教育领域人工智能技术的发展^[11]。

1.2 研究现状和相关工作

针对多模态模型的设计，目前业界逐渐形成了两大类范式^[12-14]。第一类是组合式多模态模型，即通过非统一架构将多个模态的子模型组合而成。这类模型通常包含预训练的图像模块和文本模块，各模块结构相对独立，仅在高层次通过特征对接或提示（prompt）进行松散耦合。例如，将预训练视觉编码器提取的图像特征作为输入，经过轻量级转换后馈入预训练语言模型，从而实现图文结合^[4]。组合式模型的优点在于可以充分利用单模态领域已有的大模型成果，迅速构建多模态系统；但其缺点是各模态缺乏共享的语义表示空间，难以做到真正的深度融合。此外，由于参数规模巨大，这类模型往往采用模块冻结等策略分阶段训练，无法端到端联合优化整套模型参数^[4]。

表 1.1 在 GenEval 基准上评估文本生成图像能力。“Und.”和“Gen.”分别表示“理解”和“生成”。使用外部预训练扩散模型的模型用[†]标注。

Type	Method	Single Obj.	Two Obj.	Counting	Colors	Position	Color Attri.	Overall [†]
Und. and Gen.	SEED-X [†] ^[15]	0.97	0.58	0.26	0.80	0.19	0.14	0.49
	Show-o [†] ^[16]	0.95	0.52	0.49	0.82	0.11	0.28	0.53
	D-DiT ^[17]	0.97	0.80	0.54	0.76	0.32	0.50	0.65
	LWM ^[18]	0.93	0.41	0.46	0.79	0.09	0.15	0.47
	Transfusion ^[19]	-	-	-	-	-	-	0.63
	ILLUME ^[20]	0.99	0.86	0.45	0.71	0.39	0.28	0.61
	TokenFlow-XL ^[18]	0.95	0.60	0.41	0.81	0.16	0.24	0.55
	Chameleon ^[21]	-	-	-	-	-	-	0.39
	Janus ^[5]	0.97	0.68	0.30	0.84	0.46	0.42	0.61
	Janus-Pro-1B	0.98	0.82	0.51	0.89	0.65	0.56	0.73
	Janus-Pro-7B	0.99	0.89	0.59	0.90	0.79	0.66	0.80

相较而言，第二类是统一架构的多模态模型，其采用单一模型框架同时处理图像和文本等多模态输入，将不同模态映射到共享的表示空间中。典型地，这类模型基于 Transformer 等统一架构，对图像和文本数据进行统一编码和融合建模，支持端到端训练优化整个模型参数。在统一模型中，图像和文本特征可以相互对齐融合，模型能够通过共享的表示理解二者之间的细粒度对应关系，从而在生成与理解任务上实现一体化的表现。表1.1和表1.2（引自^[28]，部分参考文献有更新）对比了当前部分生成与理解多模型模型在图像生成和图像理解任务上的性能。下面将按照是否采用统一架构，将主流视觉多模态模型分为上述两类进行综述。

表 1.2 在多模态理解基准上与最先进方法的比较。“Und.”和“Gen.”分别表示“理解”和“生成”。使用外部预训练扩散模型的模型用[†]标注。

Type	Model	# LLM Params	POPE [†]	MME-P [†]	MMB [†]	SEED [†]	GQA [†]	MMMU [†]	MM-Vet [†]
Und. and Gen.	DreamLLM [†] [22]	7B	-	-	-	-	-	-	36.6
	LaVIT [†] [8]	7B	-	-	-	-	46.8	-	-
	MetaMorph [†] [23]	8B	-	-	75.2	71.8	-	-	-
	Emu [†] [4]	13B	-	-	-	-	-	-	-
	NExT-GPT [†] [24]	13B	-	-	-	-	-	-	-
	Show-o-256 [16]	1.3B	73.8	948.4	-	-	48.7	25.1	-
	Show-o-512 [16]	1.3B	80.0	1097.2	-	-	58.0	26.7	-
	D-Dit [17]	2.0B	84.0	1124.7	-	-	59.2	-	-
	Gemini-Nano-1 [25]	1.8B	-	-	-	-	-	26.3	-
	ILLUME [20]	7B	88.5	1445.3	65.1	72.9	-	38.2	37.0
	TokenFlow-XL [26]	13B	86.8	1545.9	68.9	68.7	62.7	38.7	40.7
	LWM [18]	7B	75.2	-	-	-	44.8	-	9.6
	VILA-U [27]	7B	85.8	1401.8	-	59.0	60.8	-	33.5
	Chameleon [21]	7B	-	-	-	-	-	22.4	8.3
	Janus	1.5B	87.0	1338.0	69.4	63.7	59.1	30.5	34.3
	Janus-Pro-1B	1.5B	86.2	1444.0	75.5	68.3	59.3	36.3	39.8
	Janus-Pro-7B	7B	87.4	1567.1	79.2	72.1	62.0	41.0	50.0

1.2.1 组合式图像生成与理解多模态模型

早期多模态研究大多采用组合式架构，利用现有的视觉模型和语言模型通过设计接口结合起来，以较低的训练成本实现多模态能力。BLIP-2 模型^[29] 是其中的典型代表。BLIP-2 首先使用一个冻结的预训练图像编码器提取视觉特征，然后引入一个轻量级查询 Transformer 模块将视觉特征投射到语言语义空间，最后将处理后的图像表示输入一个大型预训练语言模型（如 Flan-T5）以生成文本。这种三级架构通过冻结大部分参数，实现了高效的跨模态预训练。实验表明，BLIP-2 在图文检索、视觉问答等任务上达到当时的最优水平（State-of-the-Art, SOTA），且仅需极少的可训练参数^[29]。与此类似，Flamingo 模型也采用了视觉编码器 + 大型语言模型的组合架构。Flamingo 使用一个预训练的感知重采样器（Perceiver Resampler）模块将图像特征适配为一系列视觉令牌插入语言模型中，利用冻结的 80B 参数语言模型实现图像到文本的生成。通过在海量图文对上微调交叉注意层，Flamingo 展示了强大的多模态少样本（Few-Shot）学习能力，在零样本视觉问答等任务上取得了优异表现^[4]。

除了以文本生成为目标的视觉-语言模型外，另一类组合式方法侧重于文本引导的图像生成^[14]。DALL·E 2 就是这方面的代表模型之一。DALL·E 2 采用两阶段架构：首先一个先验网络根据输入文本生成对应图像的 CLIP 视觉嵌入；随后扩散解码器根据该嵌入生成高分辨率图像^[30]。其中，先验网络和扩散解码器分别在大规模数据上独立训练，再串联使用以完成从文本到图像的生成。这种模块化设计利用了 CLIP 的双模态嵌入空间和扩散模型在图像生成上的强大能力，但文本和

图像生成模块间仅通过 CLIP 隐空间通信，并不共享更底层的表示。此外，OpenAI 的报告显示 DALL·E 2 主要着重于生成质量的提升，并未涉及反向的图像描述生成等任务，因而属于单向的组合式模型。Emu 模型尝试在组合架构下实现双向生成与理解^[4,31]。Emu 采用一个 Transformer 作为“通用多模态接口”：将图像先用编码器提取为视觉特征嵌入，与文本词元 (Token^[32]) 串联后输入 Transformer，利用统一的自回归目标训练模型既能预测下一个文本词元，也能回归下一个图像嵌入。经过这种跨模态序列建模训练，Emu 在图像描述、视觉问答以及文本生成图像等多种任务上都表现突出。然而需要指出的是，Emu 在文本生成图像时，并非直接由 Transformer 输出图像像素或 token，而是生成图像的连续隐变量，再交由外部预训练的扩散解码器渲染为最终图像。因此严格而言，Emu 仍属于组合范式：其视觉特征由独立模块提取，图像的最终生成也依赖于另一个外部模型。综合来看，组合式多模态模型通过模块级联，在图像描述、视觉问答和文本生图等子任务上都取得了领先效果，但由于缺乏统一的表示与联合训练，它们在跨模态迁移学习、一体化推理等方面存在局限。这种局限性推动了统一架构多模态模型的兴起。

1.2.2 图像生成与理解统一模型：基于扩散模型或流模型

扩散模型作为近年图像生成的主流技术，被引入多模态统一模型以期同时掌握图像生成和图像理解能力。最新的 Stable Diffusion 3 (SD3) 即在标准扩散生成架构中融入了多模态处理机制，引入了多模态扩散 Transformer (MMDiT) 的新架构^[33]。MMDiT 将文本和图像的表示统一为一串令牌序列，并通过自注意力机制进行联合建模。具体而言，SD3 在扩散 UNet 中加入 Transformer 块，使图像噪声图像的逐步去噪过程能够利用文本 Embedding 提供的语义信息，同时还结合了一种校正流 (Rectified Flow) 技巧来改善文本条件的对齐。凭借这些改进，Stable Diffusion 3 (SD3) 相较前代在文本控制的图像生成任务中显著减轻了角色遗漏、属性混淆等问题。不过，SD3 主要针对文本到图像的生成进行了优化，其“统一”体现在更紧密的图文融合生成上，尚未完全覆盖图像到文本的反向生成能力。

为实现真正双向的多模态统一生成，近期出现了扩散模型和自回归建模相结合的新尝试。对偶扩散 Transformer (Dual Diffusion Transformer, D-DiT) 提出了一种端到端的跨模态扩散模型，实现了图像和文本双分支扩散的统一架构^[17]。该模型在一个单一 Transformer 中同时构建图像分支和文本分支：图像分支在连续潜空间上执行扩散去噪，而文本分支在离散 token 空间执行掩码扩散。训练时，通过一个统一的极大似然目标联合优化图像生成和文本生成两方面的扩散过程，梯度可以贯通图文两个分支。Dual Diffusion 是首个支持完整视觉-语言能力的扩散模型。实

验显示，该模型在图像生成、图像描述和 VQA 等任务上达到了与同规模自回归模型相当的性能。此外，Dual Diffusion 使用 Stable Diffusion 3 的权重初始化图像分支，使模型在少量文本数据下即可快速适应文本生成任务，证明了利用预训练图像扩散模型作为初始化的可行性。这表明扩散模型的视觉先验和语言能力可以在统一框架下高效融合^[17]。

除了扩散模型，流模型（Flow）也被用于构建统一多模态模型的生成分支。JanusFlow 是这方面的代表工作^[34]。JanusFlow 将 LLM 式的自回归语言模型与 Rectified Flow 生成技术融合在一个极简架构中。与 Dual Diffusion 类似，JanusFlow 也采用视觉编码器解耦的设计，即针对图像理解和图像生成分别使用不同的视觉编码途径，同时在统一 Transformer 中对接这两种表示。其中，图像理解分支提取的高层语义特征供 Transformer 进行多模态推理，图像生成分支则通过流模型从语义空间采样生成图像数据。JanusFlow 的一个关键发现是：在大型 Transformer 框架内训练流模型并不需要对架构进行复杂改动，Rectified Flow 可以“无缝”嵌入标准的自回归训练流程。通过联合训练和表示对齐，JanusFlow 最终实现了与扩散类统一模型相当的效果：在多模态理解和生成的各项基准上，JanusFlow 的性能可媲美各任务的专门模型，并显著超过此前的统一模型方法。扩散/流范式的统一模型充分利用了连续生成模型在图像合成上的高保真优势，使统一模型在图像生成质量上保持领先的同时，兼顾了图像描述等理解任务。然而其不足之处在于，对文本的生成需要通过扩散或流的方式迭代得到，相较直接的自回归输出在效率上稍逊。此外，扩散模型对离散文本的生成需要特殊处理（如掩码噪声建模），训练过程也更加复杂。然而，随着 Dual Diffusion、JanusFlow 等工作的成功，这一路线展现出巨大的潜力——未来通过进一步优化采样效率和模态对齐，这类模型有望成为多模态统一模型的重要分支。

1.2.3 图像生成与理解统一模型：基于自回归模型

扩散模型缺乏良好的自监督学习范式，同时具有难以实现规模扩展（scale up）等问题；而流模型要求生成函数可逆，且要求雅可比行列式（Jacobian Determinant）可显式求出，这些缺陷导致模型的性能总体上受限。因此另一类统一多模态模型借鉴了目前较为成熟的大型语言模型的范式，采用自回归序列建模将多模态任务统一视作序列到序列的问题^[35]。其核心思想是：将图像等连续信号离散化为“视觉词元”（Visual tokens）序列，再与文本词元共同组成一个混合序列，用单一 Transformer 模型进行建模和生成。早期的探索如 OpenAI 的 DALL·E (2021) 已证明，通过 VQ-VAE 将图像编码为离散码字后，可训练 Transformer 以自回归方式逐像素生成逼真

图像。这一思想如今被拓展用于构建通用多模态模型。Chameleon 是 Meta 提出的混合模态早期融合模型代表^[21]。Chameleon 采用单一的 Token 序列作为模型输入，可以任意交错排列图像 token 和文本 token。在训练过程中，引入特定的视觉词典（通过 VQGAN 等获得）将图像转化为离散标记，使模型既能处理文本生成，也能输出图像序列。通过精心设计的训练策略和对齐方法，Chameleon 成功在一个模型中实现了多种任务的统一：包括视觉问答、图像描述、纯文本生成、图像生成乃至图文混合输出。值得注意的是，Chameleon 在多个基准上达到或超过了当时规模更大的专用模型的性能，例如在图像字幕生成上取得了新的最佳结果，并且在长篇多模态内容生成的人类评价中甚至比肩了 GPT-4V 等强大的多模态系统。这表明自回归统一模型在保持通用性的同时，已经具备了与专用模型竞争的能力^[21]。

然而，Chameleon 等采用单一视觉编码器为理解和生成提供视觉表示的方法也暴露出潜在问题。由于图像理解往往需要细粒度、高语义的信息，而图像生成侧重整体感知与外观重构，单一路径难以同时兼顾两种需求^[5]。针对这一问题，DeepSeek 提出了 Janus 统一模型^[5]。Janus 的特点是在保持 Transformer 统一架构的前提下，解耦视觉编码途径：为图像理解分支配置一个专门的视觉编码器（例如用于提取细粒度语义特征），为图像生成分支采用另一个独立的图像 tokenizer（用于生成所需的离散视觉词元）。两种编码得到的表示均输入同一个 Transformer 中进行多模态交互和自回归生成。这种解耦设计避免了单一视觉编码器在兼顾理解与生成时的性能权衡，大幅提升了模型对图像理解任务的表现。实验结果显示，Janus 在多个多模态理解基准上超越了先前的统一模型（如 Chameleon）的性能，并达到了一些专用视觉问答模型的水平，同时在图像生成任务上保持了强大的竞争力^[5]。在此基础上，后续的 Janus-Pro 进一步扩大了模型规模（提供 7 亿和 70 亿参数两个版本），通过更大数据集预训练将性能推向新高^[6]。Janus-Pro 的技术报告指出，随着模型容量增加和训练策略改进，统一模型的各项技能均稳步提升，展现出良好的可扩展性^[6]。

自回归统一模型的另一重要进展是 Unified-IO 2^[35]。Unified-IO 2 通过设计通用的 tokenizer 将不同类型的输入（图像像素、文本字符、音频波形、动作指令等）都离散编码到统一的语义 token 空间，再使用 Transformer 对序列进行自回归，在通用多模态评测基准 GRIT 上创造了新的纪录，并在图像生成、视觉问答、自然语言理解、视频理解、音频分类、机器人操作等广泛任务上取得了与当前最佳方法相当的结果。Unified-IO 2 的成功表明，自回归统一模型具有极强的模态扩展性和任务泛化能力：通过适当的架构设计和大规模训练，即便将更多模态纳入同一模型框架，也能保持各任务的高水平表现。相比扩散模型方案，自回归模型生成文

本的效率和准确性更高，训练目标简单（下一个 token 预测）且易于优化。同时，由于 Transformer 架构的通用性，这类模型可以方便地利用现有的加速技术和扩展插件（例如 LoRA 微调、多模态 prompt 设计等）来进一步提升能力。不过，自回归方法在高分辨率图像生成方面相对扩散模型仍有一定差距，生成长序列时的计算开销也非常大^[35]。因此，如何在保证图像生成质量的同时控制序列长度、提升生成速度，也是自回归多模态模型后续需要研究的方向。

1.3 数据集构建的相关工作

科学领域的多模态问答任务是对上述模型能力的重要检验。目前有代表性的科学问答数据集包括 ScienceQA 和 Textbook QA (TQA)。ScienceQA 是 NeurIPS 2022 提出的第一个大规模多模态科学问题数据集，包含约 21, 208 道小学到高中科学多项选择题^[11]。其中接近一半的问题附带图片情景，近半数附带文本情景，有 30.8% 的问题同时包含图文^[11]。与以往数据集不同，ScienceQA 为每道题提供了详细的讲解 (lecture) 和解释 (explanation) 作为答案的推理链路^[11]。这样的链式思维 (COT) 标注被证明对于提高模型的推理能力和可解释性大有裨益：例如，使用 GPT-3 进行少样本链式思维提示，可使 ScienceQA 的问答正确率提升 1.20%^[36]；对预训练模型 UnifiedQA 进行微调并生成解释，可比不产生解释的模型提升约 3.99% 的准确率^[11]。在该数据集上，当前最先进方法结合了多模态大模型和链式推理策略，显示出人类可解释推理对模型性能的积极影响。然而，总体而言 ScienceQA 依然具有相当难度，需要模型具备跨模态多跳推理能力。

Textbook QA (TQA) 数据集则来源于初中科学教材，包含 1076 个课节的课文和 26260 道多模态问题，其中约 12567 道题带有相应的插图或示意图^[9]。TQA 被定义为多模态机器阅读理解任务，即模型需要阅读大量篇幅的课文和图像来回答问题。与一般的 VQA（问题往往只涉及单一图像）不同，TQA 的问题上下文篇幅长、由多段文字和多个图表构成，涉及复杂的科学概念，需要模型具备长篇幅跨模态推理能力。这使得 TQA 成为极具挑战性的任务：Kembhavi 等人在提出该数据集时报告的基线结果表明，模型性能远低于人类水平^[9]。此后有研究者尝试引入记忆网络等方法来处理 TQA 中的长文档推理^[37]，一定程度上提高了准确率，但整体而言 TQA 仍未有突破性进展，很多多模态模型很难高效利用如此冗长且多样的上下文信息。

1.4 目前微调范式的不足

当前主流多模态模型的训练范式主要以大规模预训练和有监督微调（Supervised Fine-Tuning, SFT）为主^[38]。即首先在海量图文数据上进行对比学习、图文匹配、图像描述等预训练，然后在下游任务（如 VQA）上通过有标签数据微调模型参数以适配特定任务。然而，仅靠 SFT 往往存在对齐不足的问题：模型可能倾向于预训练任务中的行为，在特定场景下生成不符合用户期望的回答或图像。对于语言模型，近年来流行的解决方案是引入人类偏好强化学习（RLHF）：通过人类反馈训练奖励模型，使用强化学习（通常采用 PPO 算法）微调模型，使其输出更符合人类偏好^[39]。OpenAI 公司的 InstructGPT 正是采用了 SFT 结合 RLHF 的方法，使得 GPT-3 在遵循指令和有害内容规避方面取得了巨大改进^[39]。

相比之下，在多模态领域，将 RLHF 或其他强化学习策略用于对齐模型能力的研究还相对欠缺。一方面，多模态输出（例如一幅图像）优劣的评价比文本更难量化，获取高质量的人类反馈成本更高；另一方面，大模型的图像生成往往涉及高维连续空间，直接应用 RL 算法面临稳定性挑战。一些新兴的方法尝试改进现有策略以适应复杂场景，例如 Stanford 等提出了直接偏好优化（Direct Preference Optimization, DPO），DeepSeek 提出了群体相对策略优化（Group-Relative Policy Optimization, GRPO）^[40] 等算法，旨在提高 RL 微调的效率和稳健性^[41]。然而这些方法在视觉-语言模型上的应用尚处起步阶段。目前绝大多数多模态模型（如 BLIP 系列、LLaVA、InstructBLIP 等）在对下游任务适配时仍以有监督微调为主^[38]。因此，如何将强化学习引入多模态模型的微调过程、用以提升模型对用户指令的响应准确性和输出结果的质量，是一个亟待探索的课题。

1.5 本文主要研究内容与目标

针对当前多模态大模型在理解与生成任务融合能力不足、科学问答推理深度不够、模型输出缺乏自我纠错能力等问题，本文基于 Janus-Pro 7B 统一多模态模型，提出一套创新的二阶段微调流程，旨在通过有监督指令微调（SFT）、强化学习（RL）与自监督训练相结合的方式，提升模型在科学问答与图像生成任务上的综合能力与可解释性。




图 1.1 二阶段训练流程

本文提出的训练框架分为以下两个阶段：

阶段一：JanusPro-RL（理解优化阶段） 在该阶段，使用 ScienceQA 数据集中带有解答（solution）的样本，通过有监督微调（SFT）建立模型对科学问题的基本理解能力，再引入改进后的 GRPO 强化学习算法，以多项结构化 reward（格式规范、答案正确性、推理过程重复率、回答长度等），使用完整训练集引导模型输出结构清晰、推理合理、格式标准的回答，从而获得 JanusPro-RL 模型。

阶段二：JanusPro-SciQA（生成能力联合训练阶段） 使用第一阶段训练得到的 JanusPro-RL 模型，在不带解答的数据集（TQA）上自动生成思维链，构建推理数据集，经过筛选后在 JanusPro Base 模型上使用该数据执行 SFT 与 RL 多重训练，同时引入图像生成任务并加入图像生成的自反馈优化机制，实现理解与生成任务的联合优化，得到具备推理与图像生成能力的 JanusPro-SciQA 模型。

通过以上数据增强方法，本文在无需人工标注大量解释文本的前提下，实现了推理过程与纠错机制的可控扩展，有效提升了多模态模型在科学场景中的应用

能力。

1.6 论文工作与创新点

本文围绕 Janus-Pro 多模态模型的微调训练，在方法和应用上取得了如下创新和进展：

- 1) **提出统一多模态二阶段训练范式：**本文围绕 Janus-Pro 统一图像理解与生成架构，设计了一个结构化的二阶段多模态微调流程，提出了“SFT 预热 → 强化学习优化 → 自监督推理强化”递进式训练范式。该范式充分融合了有监督指令微调（SFT）与强化学习（RL）的优势，通过阶段性控制任务难度和对齐程度，显著提升模型在科学问答和图像生成两大任务上的性能。与传统的端到端单阶段微调方法相比，该流程更系统性地引导了统一模型在多模态输出上的行为校正和能力融合，展现出更好的稳定性与扩展性^[42]。
- 2) **实现理解与生成双任务协同优化：**本文采用统一模型框架同时支持图像理解与文本生成、图像生成任务，并在训练中引入了多任务目标与交叉自反馈监督机制，实现了视觉问答和图像生成任务之间的协同增强。通过在 ScienceQA、TQA 等科学问答数据集^[9,11]和文本生成图像任务上的评估，验证了该统一模型在复杂多模态任务中的整体性能提升。
- 3) **改进 GRPO 算法以适配多模态强化学习：**本文针对原始 GRPO 算法在多模态模型训练中的适配性问题^[43]，参考 DAPO 算法^[43]和方差感知的反馈算法^[44]，进行了以下关键性改进：根据奖励的均值和方差分布，引入奖励稀疏剪枝策略和权重动态调整策略以稳定训练信号；基于正则化的动态奖励归一化机制抑制极端偏差；结合参数高效微调方案，使大规模模型在可接受计算资源下实现策略优化。同时，我们扩展奖励至图像生成任务，提出了适配视觉生成理解统一模型的自反馈奖励设计，实现了图像生成与问答任务在同一强化学习流程下的联合优化。
- 4) **拓展多模态模型的强化对齐范式：**通过统一模型框架与多阶段训练机制的协同设计，本文将指令对齐、推理解释和多模态输出能力整合于统一训练流程之中，为多模态大模型构建提供了可复制、可扩展的范式模板。此外，本文提出的自动推理数据生成范式在训练过程中的引导效果显著，为未来构建低资源高质量推理数据集提供了可行方案。相关思想可推广至法律、医疗、编程等其他对“可解释性”与“推理深度”要求高的多模态场景。

1.7 本文的论文结构与章节安排

本文内容共分六章，各章安排如下：

- **第 1 章：绪论** 主要介绍本研究的背景与意义，分析国内外相关领域的研究现状，阐述本文的研究内容、目标以及创新点，并概述论文的结构安排。
- **第 2 章：相关基础知识和技术** 介绍多模态大模型所涉及的理论基础和关键技术，包括评价指标；Janus-Pro 7B 模型的架构与功能；综述当前多模态模型自监督微调及强化微调的策略（PG、GRPO）以及参数微调方法（Galore）；并介绍 ScienceQA 与 TQA 数据集的任务定义和挑战。
- **第 3 章：强化学习驱动的数据合成** 详细介绍基于 Janus-Pro 模型二阶段微调流程的第一阶段（含 CoT 数据的合成）的具体实施过程。包括数据预处理与指令（prompt）构建、GRPO 算法在此任务场景中的优化策略、强化微调中奖励的设计、推理链数据的生成与筛选策略等。并阐述模型微调的具体参数、过程和实验结果。
- **第 4 章：基于合成数据的有监督微调与强化微调** 详细介绍基于 Janus-Pro 模型二阶段微调流程的第二阶段，即利用原始与合成数据集对基础模型进行指令微调。此阶段旨在保持模型回答多样性的前提下，提升其在本领域下游任务上的性能。首先分析当前 GRPO 算法在此任务中存在的不足与原因，然后提出新的改进算法。新方法在保持高准确率的同时，极大地降低了资源消耗，并能够联合训练模型的图像理解与图像生成能力。最后对本章的工作进行小结。
- **第 5 章：实验** 本章对比本文优化后的 GRPO 算法与原始算法的差异与优点。验证了优化算法的有效性和高效性。
- **第 6 章：总结与展望** 对全文工作进行总结，指出本研究的贡献所在和取得的成果；同时分析当前方法的不足之处，并展望未来进一步的研究方向，例如更大规模多模态模型的训练、微调机制的改进等。

2 相关基础知识和技术

2.1 评价指标

在本研究中，我们针对多模态理解与生成任务，分别使用了以下几类评价指标来衡量模型的性能。

2.1.1 理解性能评价指标

- 1) **测试集准确率 (Accuracy, Acc)** 以未见过的测试集为评估对象，统计模型对问题（文字与图像结合）的正确回答比例。Acc 越高，说明模型在理解与推理方面越准确^[45]。
- 2) **一致性比率 (Consistency Rate, CR)** 通过对测试题目做一定程度的改动（保留原题核心原理与难度），再评估模型能否保持正确解答的能力。若改动后的题目仍被正确回答，则视为模型在推理逻辑与概念理解上具备一致性^[45-46]。CR 越高，表明模型在面对细微变化或干扰时仍能保持准确性。
- 3) **解释合理性 (Rationality Score)^[47]**

使用 GPT-4o 作为评估模型，对模型的答案解释进行自动审阅与打分。具体地：

- 将题目与模型答案（含解释部分）一并作为输入提供给 GPT-4o；
- 依据下表的量化标准，分别从逻辑一致性、语言清晰度、针对性等多个维度为解释打分；
- 每个回答评分三次取平均，最终汇总计算得到一个 1 ~ 5 的综合分数，用以衡量“解释合理性”。

实际使用的 Prompt 见附录A.1。

2.1.2 生成性能评价指标

- 1) **弗里切特距离 (Fréchet Inception Distance, FID)^[48]** 用于衡量生成图像与真实图像在分布上的差异。FID 值越低，说明生成图像与真实图像越相似，视觉质量更高。
- 2) **语义相似度**主要通过下述两种方式评估：
 - **CLIP 分数^[49]**：将生成的图像与指定语义（或文本描述）进行对比，若

图-文匹配得分较高，说明生成图像与目标语义关联度更强。

- **VQA 再验证：**将生成的图像替换到 VQA 场景中，若模型基于该图像继续回答问题且正确率较高，则表明生成图像在语义上与任务需求较为吻合。

上述指标既能反映模型对视觉信息和文本信息的泛化理解、推理、生成性能，也能帮助我们在不同任务场景下对模型进行全方位评估。

2.2 Janus Pro 架构分析

JanusPro-7B 是 DeepSeek 团队开发并开源的一个图像生成理解统一多模态模型^[6]。该模型基于 70 亿参数的预训练 Transformer 模型 DeepSeek LLM-7B^[50]，架构见图2.1 (引自^[5])，使用解耦视觉编码的设计。具体而言，JanusPro 对视觉语义信息的处理分为两个独立的通路，一条用于多模态视觉理解 (Visual Understanding)，另一条用于视觉生成 (Visual Generation) 从而缓解了二者在特征表征上的冲突。这样设计的理由是，视觉理解更需要捕获图像的高层语义和图像的“判别性/对齐性”特征^[51-52]，而视觉生成更需要捕获图像的底层细节和局部信息^[53-54]。团队在实验中发现，如果使用单一编码器进行视觉理解和生成的编码，则会产生两种任务性能的权衡现象 (tradeoff)，即在充分训练的模型上，一种任务性能的提升伴随另一种任务性能的下降^[6]。

这种设计最早由 Janus 模型提出。Janus 是 JanusPro 的前身 (1.3B 参数规模)，其创新在于为图像理解和生成分别引入不同的视觉编码方式。实验证明，该解耦策略使一个模型在图像理解和图像生成两方面都能取得优异性能。JanusPro-7B 在 Janus 的基础上，进一步扩展了模型规模 (从 1B 扩展到 7B 参数) 并改进了训练策略和数据。这使得 JanusPro-7B 在多模态理解基准 (例如 MMBench) 上达到 79.2 的成绩，超越了 Janus 原型 (69.4) 以及其他统一模型如 TokenFlow (68.9) 和 MetaMorph (75.2)。同时在文本生成图像的指令遵循任务 (GenEval 基准) 上，JanusPro-7B 得分 0.80，明显优于 Janus (0.61) 和 OpenAI 的 DALL-E 3 (0.67) 等。

在理解通路中，模型采用预训练的 SigLIP-L 图像编码器将输入图像映射为高维特征 (例如，将 384×384 分辨率的图像编码为扁平化的特征序列)。这些图像特征经过一个“理解适配器” (Understanding Adaptor) 投射到语言模型的输入空间，然后与文本序列一起送入 Transformer。而在生成通路中，模型使用一个向量量化变分自编码器分词器 (Vector Quantized Variational Autoencoder tokenizer, VQ-VAE tokenizer) (codebook 下采样率为 16) 将图像离散化为图像 token 序列，再通过“生




图 2.1 JanusPro 模型架构

成适配器” (Generation Adaptor) 将这些图像代码的嵌入映射到语言模型输入空间。然后, JanusPro 将文本词元 (Token) 序列、图像理解特征序列、图像生成词元序列级联形成统一的多模态序列, 输入到同一个 Transformer 中进行处理, 利用自回归机制生成输出。模型在输出端配备了两个预测头: 对于文本输出使用 Transformer 自带的语言建模头, 对于图像生成任务则使用一个随机初始化的图像词元预测头。整个架构遵循纯自回归范式, 无需额外的复杂模块, 即可实现从文本到图像的生成。这种设计正是 Janus 名称的由来: 一方面利用 SigLIP 等高维语义编码器处理理解任务, 另一方面利用 VQ 编码器提供低维离散表示处理生成任务^[5]。两个“面孔”分别专精语义抽象和细节合成, 在统一的 Transformer 架构中融合, 互不冲突。

2.3 多模态模型微调策略

2.3.1 有监督微调

有监督微调 (Supervised Fine-Tuning, SFT), 即利用标注的输入-输出对, 让模型学习将输入映射到期望的输出^[36,39,55]。在我们的场景中, 这意味着用 TextbookQA 数据集中大量的问答对来微调 JanusPro-7B, 使其输出正确答案 (和解释)。有监督微调的训练目标通常是最小化模型输出与参考答案之间的交叉熵损失, 等价于最大化模型对正确答案序列的概率。形式化地, 对于数据集 $D = (x^{(i)}, y^{(i)})$ ($x^{(i)}$ 为第 i 个问题及相应内容, $y^{(i)}$ 为对应的正确答案或答案 + 解释序列), 有监督微调优化如下目标函数^[36]:

$$L_{\text{SFT}}(\theta) = -\mathbb{E}_{(x,y) \sim D} [\log P_{\theta}(y | x)], \quad (2.1)$$

其中 θ 为模型参数。这一目标就是让模型按照参考输出 y 来调节其条件概率分布。通过梯度下降, 我们不断调整模型参数以降低 L_{SFT} , 从而提高模型在已知问答对

上的准确率。

2.3.2 策略梯度 (Policy Gradient, PG)

策略梯度方法是强化学习 (RL) 中用于优化策略的一类基础方法。在语言模型生成任务中, 策略 $\pi_{\theta}(y|x)$ 表示模型在给定输入 x 的条件下生成输出序列 y 的概率分布, 其中 θ 表示模型参数^[56-57]。

与有监督学习不同, 强化学习不需要每个动作序列都有明确标签, 而是通过奖励函数 $R(x, y)$ 来引导策略优化。在科学问答场景中, 我们可以设定奖励函数, 例如:

- 回答正确则奖励 $R(x, y) = 1$;
- 回答错误则奖励 $R(x, y) = -1$;

或者对于解释质量高的输出, 赋予更高奖励等等。我们的目标是最大化策略下生成输出时的期望奖励, 其目标函数如下^[56]:

$$J(\theta) = \mathbb{E}_{x \sim D, y \sim \pi_{\theta}(\cdot|x)} [R(x, y)], \quad (2.2)$$

其中期望是对训练集中的问题 x 及模型当前策略下生成的输出 y 取平均。

为优化 $J(\theta)$, 策略梯度方法给出了其梯度估计:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{x, y \sim \pi_{\theta}} [R(x, y) \nabla_{\theta} \log \pi_{\theta}(y|x)]. \quad (2.3)$$

即 Reinforce 算法的基础形式^[58]。实践中, 为避免方差大、收敛速度慢等问题。为提升稳定性和性能, 后续研究提出了多种改进算法, 如:

- 信赖域策略优化 (Trust Region Policy Optimization, TRPO)^[59];
- 近端策略优化 (Proximal Policy Optimization, PPO)^[60]
- 组相对策略优化算法 (Group Relative Policy Optimization, GRPO)^[40]

这些方法通过限制每次策略变化幅度或引入剪裁机制, 有效提升了大模型微调中的训练稳定性。后文将进一步介绍 GRPO 算法及其在多模态语言模型微调中的应用。

2.3.3 组相对策略优化 (GRPO) 算法

GRPO (Group Relative Policy Optimization) 是 DeepSeek 团队提出的一种大语言模型的强化微调方法^[40]。其核心思想是基于组的相对奖励优化, 通过采样多种

输出并进行比较，估计策略优势。由于去除了 Value 模型，显著降低了计算与内存开销。算法细节于3.1中说明。

GRPO 在实践中展现出良好的训练稳定性和性能，在 DeepSeek-R1-Zero 实验中，即便完全不依赖人工标注，仅依靠硬规则反馈和 GRPO 策略，大模型也逐步学会生成更复杂的思维链解释 (Chain-of-Thought)，表现出推理能力的自我进化过程^[42]。

与 PPO 等其他策略梯度算法相比相比，GRPO 的主要优势在于无需 Critic 网络，不使用值函数估计，且能通过一组样本之间的对比关系构造稳定的优化目标（见图2.2，引用自^[40]）。这种无值函数的设计大大降低了训练资源的需求，特别适合在资源受限条件下对 JanusPro-7B 这类多模态大模型进行强化微调。




图 2.2 GRPO 与 PPO 流程对比

在我们对 JanusPro-7B 的微调中，GRPO 被用于优化模型在 TextbookQA 数据集上的表现，奖励信号由答案准确性、解释合理性等组成。模型将逐步学会在生成过程中更倾向于给出正确且逻辑清晰的回答，从而提升在下游领域任务的实用性。

2.4 参数微调方法

2.4.1 Galore

GaLore 方法通过对梯度矩阵施加低秩投影，实现内存高效的全参数训练^[61]。其原理是随着模型训练的逐渐收敛，参数梯度的秩的上界逐渐减小，故可认为模型参数的梯度是低秩的，从而大大减小搜索空间^[61]。具体地，设某层权重为 $W \in \mathbb{R}^{m \times n}$ ，其梯度为 $G \in \mathbb{R}^{m \times n}$ 。GaLore 将 G 投影到预定义的秩为 r 的低维子空间中 ($r \ll \min(m, n)$)，再映射回原空间用于更新。

GaLore 在 LLaMA-1B 和 7B 模型上从零预训练，其验证困惑度几乎与全参数微调一致，甚至略优。作者报告在单张 24GB GPU 上，结合 8-bit 优化器，可成功预训练 LLaMA-7B 模型。

在下游任务（如 GLUE）中，RoBERTa-Base 使用秩 $r = 4$ 的 GaLore 微调后获得平均得分 85.89，优于同秩 LoRA (85.61)，接近全微调（约 85.9）。说明 GaLore 在极大节省显存的同时，保留了几乎全部的性能^[61]。

GaLore 用低秩子空间投影代替高维梯度计算，支持优化器状态压缩和梯度近似。其逐步切换子空间方式保证了累积更新接近全参数微调，是一种在内存受限场景下可行、稳定、性能有保障的全精调替代方案^[61]。

2.5 数据集介绍

本研究使用 Textbook QA 数据集^[9]中的一部分进行训练，使用剩余部分和 Science QA 数据集^[11]进行测试。

Textbook QA 数据集^[9]是一个面向多模态机器阅读理解任务（Multi-Modal Machine Comprehension, M3C）的标准基准数据集。通过提供包含文本与图像的上下文信息，要求模型进行综合理解以回答对应问题。TQA 数据集的构建素材源自初中科学教材，每道题目都配有一个知识范围受限的上下文材料，确保问题解答所需信息均在提供内容中。每节课包含一定数量的多模态教学材料，包括分主题组织的文本内容、插图及教学示意图，所有图像都与其所在主题进行关联。为充分利用模型的现有知识，我们只选用数据集中的图片-问题-答案部分，不使用上下文提示。

ScienceQA 收集自小学和高中科学课程，包含 21,208 个多模态多项选择科学问题选择题^[11]。在 ScienceQA 的问题中，10,332 个 (48.7%) 具有图像上下文，10,220 个 (48.2%) 具有文本上下文具有文本上下文，6,532 个 (30.8%) 两者均有。大多数问题都附有基础讲座 (83.9%) 和详细的解释 (90.5%)。讲座和解释分别提供了一般外部知识和得出正确答案的具体原因。^[11]

ScienceQA 与以前的数据集相比，具有更丰富的领域多样性，来自三个学科：自然科学、语言科学和社会科学。每个主题中的问题首先按主题分类，然后按类别分类，最后按解题技能分类。^[11]

2.6 本章小结

本章阐述了与本文研究相关的基础知识和技术，首先介绍了图文理解和生成的评价指标，接着介绍了本文使用的预训练模型的架构，然后介绍了微调策略和参数微调方法，最后简要介绍了本文使用的训练和测试数据集。

3 强化学习驱动的推理数据合成

本章中，我们首先对 JanusPro-7B 基础模型进行强化微调，增强模型在复杂推理数据生成中的表现。

然后，我们利用其生成高质量的 CoT (Chain-of-Thought) 推理数据。为确保数据质量，我们引入 GPT-4o 作为辅助评估器，对生成内容进行自动评分，并辅以人工筛选，从而验证生成数据在逻辑性、相关性及正确性等方面均达到预期标准。

3.1 GRPO 算法

GRPO^[40]的基本流程如下：针对一个给定的输入（如问题 q ），使用当前旧策略 $\pi_{\theta_{\text{old}}}$ 生成 G 个候选输出 $\{o_1, o_2, \dots, o_G\}$ 。对每个输出计算奖励 $r_i = R(q, o_i)$ ，然后基于组内均值与标准差计算标准化优势：

$$A_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G)}, \quad (3.1)$$

其中 A_i 表示第 i 个样本的相对优势，高于平均的输出获得正值优势，低于平均的获得负值。

在此基础上，GRPO 结合了 PPO 的概率比剪裁策略，构建如下优化目标^[40]：

$$\begin{aligned} \mathcal{J}_{\text{GRPO}}(\theta) = \mathbb{E}_{q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot | q)} [& \\ \frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \min \left(\frac{\pi_{\theta}(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} | q, o_{i,<t})} \hat{A}_{i,t}, \right. & \\ \left. \text{clip} \left(\frac{\pi_{\theta}(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} | q, o_{i,<t})}, 1 - \epsilon, 1 + \epsilon \right) \hat{A}_{i,t} \right) & \\ - \beta \cdot \mathbb{D}_{\text{KL}} [\pi_{\theta}(\cdot | q) \| \pi_{\text{ref}}(\cdot | q)] & \end{aligned} \quad (3.2)$$

其中 ϵ 为剪裁阈值， π_{ref} 为参考策略模型， β 为 KL 正则系数^[39]。该目标函数在每一组采样上进行归一化更新，有效引导策略趋向于高奖励的相对优势输出。在 DeepSeek R1^[42] 中，团队采用了基于规则的 Reward 函数，避免了模型对 Reward 模型的奖励破解行为 (Reward Hacking)。

算法 3.1: 组相对策略优化 (GRPO) 算法^[40]

输入: 初始策略模型 $\pi_{\theta_{\text{init}}}$, 奖励模型 r_{φ} , 任务提示集 $\mathcal{D}$, 超参数 ϵ, β, μ
输出: 优化后的策略模型 π_{θ}

- 1 初始化策略模型: $\pi_{\theta} \leftarrow \pi_{\theta_{\text{init}}}$;
- 2 **对于** $iteration = 1$ **转到** I **进行**
- 3 设参考策略模型: $\pi_{\text{ref}} \leftarrow \pi_{\theta}$;
- 4 **对于** $step = 1$ **转到** M **进行**
- 5 从任务数据集中采样一批问题 $\mathcal{D}_b \subset \mathcal{D}$;
- 6 更新旧策略模型: $\pi_{\theta_{\text{old}}} \leftarrow \pi_{\theta}$;
- 7 **对于每个** 问题 $q \in \mathcal{D}_b$ **进行**
- 8 用旧策略模型生成 G 个候选输出序列 $\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)$;
- 9 对每个输出 o_i , 通过奖励模型 r_{φ} 计算奖励 $r_i = R(q, o_i)$;
- 10 对每个输出的每个 token $o_{i,t}$, 计算其相对优势 $\hat{A}_{i,t}$ (基于组归一化);
- 11 **对于** $GRPO\text{-}iter = 1$ **转到** μ **进行**
- 12 最大化 $\mathcal{J}_{\text{GRPO}}(\theta)$ (式3.2), 更新策略参数 θ ;
- 13 使用回放机制 (replay mechanism) 持续训练奖励模型 r_{φ} ;
- 14 **返回** π_{θ}


3.2 GRPO 算法优化: 增强推理可靠性与训练稳定性

图 3.1 阶段 1: GRPO 流程图

在此任务中, GRPO 算法有几点缺陷^[43,62]:

- 1) 由于任务需要生成用于数据合成的多样化输出, 模型策略不应过于单一, 即策略熵不应过低。然而在 GRPO 训练过程中观察到, 策略熵会迅速下降^[43]。以常用的 $\epsilon = 0.2$ 为例, 设两个动作的初始概率分别为 $\pi_{\text{data}}(o_i|q) = 0.01$ 和 0.9 , 更新后的最大概率分别为 0.012 和 1.08 。可以看出, 高概率 token (如

- 0.9) 的更新约束较弱, 而低概率 token 则很难获得显著提升, 从而限制了策略分布的探索性。
- 2) 使用同组中所有输出的 reward 同时进行强化微调, 没有考虑到 reward 的分布情况, 可能减慢训练。
 - 3) 原始的 GRPO 算法采用样本级损失计算, 它首先在每个样本内按词元平均损失, 然后汇总样本间的损失。由于所有样本在损失计算中被赋予相同的权重, 较长响应中的词元对整体损失的贡献可能会非常低, 从而产生两种不利影响: 首先, 对于高质量的长样本, 该效应会阻碍模型学习其中的推理模式。其次, 过长的样本通常表现出低质量模式, 如胡言乱语或简单复读。因此, 样本级损失计算由于无法有效地惩罚长样本中的这些不良模式, 导致熵和响应长度病态地增加^[43]。
 - 4) 当前对响应长度采用分段线性奖励函数, 但该方法未考虑问题本身的难度差异。此外, 长度奖励斜率等超参数对模型性能影响较大^[62]。同时, 模型可能在某次训练中随机猜中正确答案, 并在此基础上“记住”该答案, 之后即使推理过程存在严重错误, 也可能输出正确答案。更严重的是, reasoning 过程可能与最终答案毫无关联, 从而影响 reasoning 的可解释性与一致性。

我们部分参考解耦剪裁与动态采样策略优化 (Decouple Clip and Dynamic sAmpling Policy Optimization, DAPO) 算法^[43], 做以下几点改进:

- 1) DAPO 算法为解决策略熵过低与样本级损失不稳定的问题, 对上界和下界使用不同的非对称剪裁阈值, 同时改用 Token 级损失^[43]。此时3.2修改为:

$$\begin{aligned}
 \mathcal{J}_{\text{GRPO}^*}(\theta) = & \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\right. \\
 & \frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \right. \\
 & \left. \left. \text{clip} \left(r_{i,t}(\theta), 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}} \right) \hat{A}_{i,t} \right) \right] \\
 & - \beta \cdot \mathbb{D}_{\text{KL}} [\pi_{\theta}(\cdot|q) \parallel \pi_{\text{ref}}(\cdot|q)] \\
 & \text{s.t. } 0 < |\{o_i \mid \text{is_equivalent}(a, o_i)\}| < G
 \end{aligned} \tag{3.3}$$

与 DAPO 算法^[43]不同, 为尽可能保留原模型的能力, 我们保留 GRPO 中的 KL 散度项, 但系数 β 逐步衰减。

- 2) 为了解决 GRPO 在策略更新中未考虑 reward 分布差异的问题, 本文在优化过程中引入两项改进策略: 首先, 类似 DAPO 算法^[43], 我们仅选取相对优势显著的样本 (即满足 $|\hat{A}_i| > \mu$) 参与梯度更新; 其次, 在 reward 加权求和时,

若某一组样本的 reward 方差较大, 则给予该组样本较大的权重, 从而提升训练过程中对高不确定性样本的关注程度。最终的加权目标函数片段表达为:

$$\sum_{i=1}^G \mathbb{I}(|\hat{A}_i| > \mu) \cdot w_i \cdot r_i,$$

其中 $\mathbb{I}(\cdot)$ 表示指示函数, 仅对满足条件的样本施加奖励更新。实验证明, 这样做有利于减小方差, 提高微调效率。

- 3) 为了解决现有长度奖励机制未能充分考虑问题难度, 以及简单线性奖励所带来的强单调归纳偏置^[63] (通常仅鼓励输出更长或更短, 而非上下文相关的适宜长度) 等问题, 本文借鉴了 SimpleRL-ZOO^[64] 的思想, 对 reasoning 阶段的奖励 (reward) 设计进行了显著改进。我们的方法引入了与问题复杂度相关的精细化长度控制, 并辅以专门的推理质量评估:

- **难度自适应与目标导向的长度奖励:** 我们认识到最优的推理 (reasoning) 长度往往与问题的复杂度相关, 因此首先为每个 VQA 样本建立了一个难度评分。利用经过适当提示 (prompt) 的基础模型 (Base Model), 我们评估原始样本的难度, 评分范围为 0 至 11 分, 对应教育等级 Grade 1 至 Grade 12 (h)。鉴于我们的数据集主要包含中学阶段的科学问答题, 我们设定一个预期: 中等难度 (例如 $h = 5.5$) 的问题应该对应大约 128 个 token 的推理长度。

为了超越线性奖励的局限并实现精确的长度控制, 我们设计了一种峰值裁剪 (peaked, clipped) 奖励函数^[63]。该函数围绕一个根据难度自适应调整的目标长度 $K(h) = 128 \times (\frac{h-5.5}{11} + 1)$ 构建, 明确地编码了我们关于难度与期望长度之间关系的先验知识。奖励函数定义如下:

$$\text{reward}(x) = \begin{cases} \max\{0, a[x - K(h)]^3 + 1\}, & x < K(h) \\ \max\{0, -a[x - K(h)]^3 + 1\}, & x \geq K(h) \end{cases} \quad (3.4)$$

其中, x 是生成推理的 token 长度, h 是难度评分 (0-11), 缩放因子 $a = 5 \times 10^{-7}$ 控制峰值的尖锐程度。

该函数 (如图 3.2 所示) 相比简单的线性或单调裁剪奖励具有以下优点: **(a) 精确的自适应控制:** 直接激励模型生成接近难度自适应目标长度 $K(h)$ 的推理, 克服了线性奖励的单调偏置。 **(b) 双向惩罚:** 奖励在峰值两侧均下降, 主动惩罚过短和过长的输出, 从而抑制不充分的解释以




图 3.2 难度自适应长度奖励函数。峰值位置随难度 h 移动，在目标长度 $K(h)$ 处提供最大奖励 (1.0)，并同时惩罚过短和过长的输出。

及冗长无效的推理。**(c) 平滑峰顶与稳定性：**峰值附近平滑、准对称的结构（在 $K(h)$ 处梯度为零）提供了缓和的激励格局（incentive landscape），可能允许在期望长度范围内实现更大的措辞多样性。 $\max\{0, \dots\}$ 裁剪确保奖励有下界（非负），通过防止极端长度偏差产生任意大的负信号，有助于训练稳定性。**(d) 正向激励：**对达到目标长度给予最大为 1 的奖励，提供了直接的正向强化信号。

- **用于对齐的推理质量奖励：**为了缓解模型“记住答案”但推理过程错误、无关甚至完全是幻觉的现象，我们实现了一个有条件的质量评估阶段。如果在给定输入的一批 G 个候选输出中，超过 60% 能得出正确答案（这暗示模型可能在利用某种“捷径”），我们将使用 GPT-4o-mini 模型来评估这些高准确率候选者的推理部分。评估维度包括相关性、逻辑连贯性和事实正确性。这些评分随后被用来调整（modulate）奖励信号，明确引导模型生成不仅能导出正确答案，而且本身内在合理（intrinsically sound）、可解释且一致的推理过程^[44]。
- **解耦优化：**我们两部分奖励结构的结合，促进了一个对推理过程更解耦的优化过程。由峰值长度奖励（第一部分）提供的强烈的局部化效应（strong localization）鼓励强化学习智能体首先满足与难度级别相适应的长度约束。随后，有条件的质量奖励（第二部分）可以有效地在合适的长度范围内，优化推理内容的语义和逻辑层面。这种方法旨在同时实现形式上的充分性（长度）和实质上的质量（推理内容）。

综上所述，我们最终的强化学习优化目标建模如下：

- 1) **有效样本集合**首先，针对一次采样得到的多条候选序列 $\{o_1, o_2, \dots, o_G\}$ ，我

们根据每条序列的优势值 $\hat{A}_i$ (后文定义) 筛选出满足下式的“高价值”子集:

$$G' = \left\{ i \mid |\hat{A}_i| > \mu, i = 0 \dots G \right\}. \quad (3.5)$$

只有当候选序列的优势显著大于阈值 μ 时, 才会被纳入最终的梯度更新。

2) 目标函数

我们的优化目标函数 $\mathcal{J}_{\text{GRPO}^*}(\theta)$ 综合考虑了所有有效样本序列在每个 Token 上的策略梯度, 并引入可剪切的策略比值以稳定训练。其形式如下:

$$\begin{aligned} \mathcal{J}_{\text{GRPO}^*}(\theta) = & \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^{G'} \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\right. \\ & \frac{1}{\sum_{i=1}^{G'} |o_i|} \sum_{i=1}^{G'} \sum_{t=1}^{|o_i|} \min(r_{i,t}(\theta) \cdot \hat{A}_{i,t}, \\ & \quad \left. \text{clip}(r_{i,t}(\theta), 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}}) \cdot \hat{A}_{i,t}) \right] \\ & - \beta \cdot \mathbb{D}_{\text{KL}}[\pi_{\theta}(\cdot|q) \parallel \pi_{\text{ref}}(\cdot|q)] \\ & \text{subject to } 0 < |\{o_i \mid \text{is_equivalent}(o_i, a) = \text{True}\}| < G'. \end{aligned} \quad (3.6)$$

其中, 约束条件保证: 在采样序列中至少有一个与参考答案 a 等价, 但不至于所有序列都与 a 完全相同, 从而可学习差异化的输出。 $r_{i,t}(\theta)$ 为:

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}. \quad (3.7)$$

$\hat{A}_{i,t}$ 为整条序列 o_i 的统一优势值 $\hat{A}_i$:

$$\hat{A}_{i,t} = \hat{A}_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G)}, \quad (3.8)$$

其中 r_i 为该序列的综合奖励分数 (见下文), $r_1, \dots, r_G$ 表示同组内所有序列的得分集合。

3) 综合奖励函数

我们从回答准确性 (accuracy)、推理长度 (length)、输出格式 (format)、推理相关度 (reasoning relevance) 四个方面为每条序列 o_i 计算奖励值 r_i [44], 公式如下:

$$r_i = w_0 \cdot \text{reward}_{\text{acc}} + w_1 \cdot \text{reward}_{\text{length}} + w_2 \cdot \text{reward}_{\text{format}} + w_3 \cdot \text{reward}_{\text{reasoning relevance}}. \quad (3.9)$$

各项具体定义如下。

- (a) **Answer Accuracy** ($\text{reward}_{\text{acc}}$) - 若输出的 choice text 与正确答案匹配, 则加 0.5, 否则扣 0.5; - 若输出的 choice index 与参考 index 一致, 则再加 0.5, 否则扣 0.5。
- (b) **Length Reward** ($\text{reward}_{\text{length}}$) 使用一个三次函数 (cubic-based) 来建模偏好, 鼓励输出长度的均值在约 128 Tokens 左右。如果过长或过短, 则分值会相应衰减, 具体形式可参考公式 3.4。
- (c) **Format Reward** ($\text{reward}_{\text{format}}$) 分为硬格式与软格式两部分:
 - *Strict Format Match (Hard Format)*: 若输出缺失必要结构或不符合规范正则表达式, 则记 0 分, 否则 1 分, 再乘以权重 0.5。
 - *Soft Format Bonus*: 要求输出中 “恰好且仅出现一次” 以下四个标签: ‘<think>’, ‘</think>’, ‘<choice_text>’, ‘<choice_index>’。每个符合条件加 0.25, 最多 1 分, 再乘以权重 0.5。
- (d) **Reasoning Relevance** ($\text{reward}_{\text{reasoning relevance}}$) 当一组序列中超过 60% 均选对答案时才启用该奖励, 否则该项记为 0。启用后, 按照以下四个维度各得 0.25 分, 总计 1 分: (1) Reasoning 与最终答案具关联性; (2) Reasoning 逻辑链清晰、结构合理; (3) Reasoning 中的知识点或结论事实准确; (4) Reasoning 采用教师风格表达 (如 “we can infer...”, “thus...”, “because...”)。

4) 动态权重调整

$$w_i = \frac{\beta_{w_i} \text{Var}(\text{reward}_i)}{\sum_i \beta_{w_i} \text{Var}(\text{reward}_i)} = \frac{\beta_{w_i} \frac{1}{G} \sum_{j=1}^G (\text{reward}_{i,j} - \mu_i)^2}{\sum_{i=0}^3 \beta_{w_i} \sum_{j=1}^G (\text{reward}_{i,j} - \mu_i)^2} \quad (3.10)$$

四项奖励方差的初始权重设为

$$\beta_{w_i} = [\beta_{w_0}, \beta_{w_1}, \beta_{w_2}, \beta_{w_3}] = [0.3, 0.2, 0.45, 0.05]. \quad (3.11)$$

其中, 为了令模型先掌握基本格式规范, 再逐步转向推理深度, 我们对 β_{w_2} (format) 和 β_{w_3} (reasoning relevance) 进行线性衰减控制:

$$\beta_{w_2} = \max(0.25, 0.45 - \lambda \cdot t), \quad (3.12)$$

$$\beta_{w_3} = 0.5 - \beta_{w_2}, \quad (3.13)$$

其中 t 为训练轮数, λ 为衰减系数。

5) **KL 散度项**我们使用对 KL 散度的无偏估计^[65]:

$$\begin{aligned} \mathbb{D}_{\text{KL}}[\pi_{\theta}(\cdot | q) \parallel \pi_{\text{ref}}(\cdot | q)] &= \sum_x \pi_{\theta}(x | q) \ln \left[\frac{\pi_{\theta}(x|q)}{\pi_{\text{ref}}(x|q)} \right] \\ &= \sum_x \pi_{\text{ref}}(x | q) \underbrace{\frac{\pi_{\theta}(x|q)}{\pi_{\text{ref}}(x|q)}}_{r(x)} \ln[r(x)] \end{aligned} \quad (3.14)$$

注意到:

$$\sum_x \pi_{\text{ref}}(x | q) [r(x) - 1] = \sum_x \pi_{\theta}(x | q) - \sum_x \pi_{\text{ref}}(x | q) = 1 - 1 = 0. \quad (3.15)$$

因此由式3.14

$$\begin{aligned} \mathbb{D}_{\text{KL}}[\pi_{\theta}(\cdot | q) \parallel \pi_{\text{ref}}(\cdot | q)] &= \sum_x \pi_{\text{ref}}(x | q) [r(x) \ln r(x) - (r(x) - 1)] \\ &= \mathbb{E}_{x \sim \pi_{\text{ref}}(\cdot | q)} [r(x) \ln r(x) - (r(x) - 1)]. \end{aligned} \quad (3.16)$$

$$\text{同时, 系数 } \beta(t) = \begin{cases} \beta_0(1 - \frac{t}{T}), & \text{若 } 0 \leq t \leq T \\ 0, & \text{若 } t > T \end{cases}$$

通过上述组合型奖励函数与优势序列筛选机制, 我们在强化微调阶段可同时优化答案准确性、格式规范性和推理质量。奖励的动态加权则帮助模型逐步过渡, 从初始的格式化输出到更加精准且条理清晰的最终推理答案, 实现了在多重目标间的平衡和协同提升。

算法 3.2: GRPO* ;

改进的组相对策略优化 (GRPO) 算法

输入: 初始策略模型 $\pi_{\theta_{\text{init}}}$; 奖励模型 r_{φ} ; 任务提示集 $\mathcal{D}$; 剪裁超参数 $\epsilon_{\text{low}}, \epsilon_{\text{high}}$; KL 约束系数 β_0 ; 相对优势阈值 μ ; 训练轮数 I ; 每轮步数 M ; 动态衰减系数 λ ; 长度奖励参数 $a = 5 \times 10^{-7}$; 难度等级 $h \in \{0, \dots, 11\}$

输出: 最终优化后的策略模型 π_{θ}

1 **初始化:** $\pi_{\theta} \leftarrow \pi_{\theta_{\text{init}}}$; 设 $t = 0$; // 初始训练轮计数

2 **对于** $\text{iteration} = 1$ **转到** I **进行**

3 **更新 KL 系数:** $\beta(t) = \begin{cases} \beta_0(1 - \frac{t}{T}), & 0 \leq t \leq T, \\ 0, & t > T \end{cases}$

4 设参考策略模型: $\pi_{\text{ref}} \leftarrow \pi_{\theta}$;

5 **对于** $\text{step} = 1$ **转到** M **进行**

6 从数据集 $\mathcal{D}$ 采样一批问题 $\mathcal{D}_b \subset \mathcal{D}$;

7 备份旧策略模型: $\pi_{\theta_{\text{old}}} \leftarrow \pi_{\theta}$;

8 **对于每个** 问题 $q \in \mathcal{D}_b$ **进行**

9 用旧策略模型 $\pi_{\theta_{\text{old}}}$ 生成 G 个候选输出序列 $\{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot | q)$;

10 对每个输出 o_i , 通过奖励模型 r_{φ} 计算其综合奖励分数 r_i , 其中:

$r_i = w_0 \cdot \text{reward}_{\text{acc}} + w_1 \cdot \text{reward}_{\text{length}} + w_2 \cdot \text{reward}_{\text{format}} + w_3 \cdot \text{reward}_{\text{reasoning relevance}},$

并根据长度 $x = |o_i|$ 和问题难度 h 计算 $\text{reward}_{\text{length}}$ (参考式 (3.4)), 以及在正确率超过 60% 时由 GPT-4o-mini 对推理质量进行评分;

11 **仅选取相对优势显著序列:** 计算每条序列 o_i 的优势值

$\hat{A}_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G)};$

12 令 $\mathbb{I}(|\hat{A}_i| > \mu)$ 为指示函数, 保留 $|\hat{A}_i| > \mu$ 的序列纳入最终梯度更新;

13 **对于** $\text{GRPO-iter} = 1$ **转到** μ **进行**

14 **计算 Token 级的目标函数** $\mathcal{J}_{\text{GRPO}^*}(\theta)$ (式(3.3)), 即对各 Token 的策略比值 $r_{i,t}(\theta)$ 做非对称剪裁:

$$\min\left(r_{i,t}(\theta)\hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}})\hat{A}_{i,t}\right),$$

其中: $r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} | q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} | q, o_{i,<t})}$, 并加上 KL 散度惩罚项 $-\beta(t) \cdot \mathbb{D}_{\text{KL}}[\pi_{\theta} \parallel \pi_{\text{ref}}]$ 。

15 **对组内方差加权:** 若某组样本的 r_i 方差较大, 则提升该组权重 w_i ; 整体训练中对各维度分配动态权重:

$$w_i = \frac{\beta_{w_i} \text{Var}(\text{reward}_i)}{\sum_k \beta_{w_k} \text{Var}(\text{reward}_k)},$$

并更新策略参数 θ 使上述目标最大化;

16 $t \leftarrow t + 1$;

17 **返回** π_{θ}

3.3 Galore 算法

对于2.4.1中的低秩梯度，我们一般采用单侧投影（如 $m \leq n$ ），设 $P \in \mathbb{R}^{m \times r}$ ，压缩梯度为^[61]：

$$G_r = P^\top G, \quad (3.17)$$

优化器会先在低秩空间中更新 G_r ，然后再将其映射回原空间。完整的梯度更新表达为：

$$W \leftarrow W - P\rho(P^\top G), \quad (3.18)$$

其中 $\rho(\cdot)$ 表示如 Adam 优化器在低维空间中对压缩梯度的非线性变换（带有动量、缩放等操作）。这种投影-更新-回投影策略是 GaLore 的核心，显著减少了需要维护的梯度与动量维度，并保证计算有效性^[61]。

经验观察表明不同 token 或样本产生的梯度具有强相关性，说明有效信息集中在少数方向上。GaLore 原论文中显示^[61]，这些主方向在训练中变化缓慢，可间隔若干步更新一次投影子空间。

在 Adam 中，优化器在低秩空间中执行动量计算：

$$M_t = \beta_1 M_{t-1} + (1 - \beta_1) R_t, \quad (3.19)$$

$$V_t = \beta_2 V_{t-1} + (1 - \beta_2) (R_t \circ R_t), \quad (3.20)$$

其中 $R_t = P_t^\top G_t$ ， $ho(R_t) = \hat{M}_t / (\sqrt{\hat{V}_t} + \epsilon)$ ，并最终恢复原维度： $\tilde{G}_t = P_t \cdot \rho(R_t)$ 。

若 $M_t, V_t \in \mathbb{R}^{r \times n}$ ，优化器状态开销下降约 $\frac{r}{m}$ 。实验证明，GaLore 将 Adam 状态显存减少最高达 65.5%^[61]。

不同于 LoRA 固定低秩结构（ $W = W_0 + LR^\top$ ），GaLore 每步使用不同投影子空间近似梯度，长期来看等效于在多个子空间累计的全参数更新^[61]。

训练 k 个子空间后总更新为：

$$W_{T_{\text{final}}} - W_0 = \sum_{i=1}^k \Delta W^{(i)}, \quad (3.21)$$

每项 $\Delta W^{(i)}$ 秩至多为 r ，总更新秩上界为 $k \cdot r$ 。因此只要子空间更新频率充分，GaLore 最终可覆盖高维更新方向^[61]。

算法 3.3: 带 GaLore 的 Adam 优化器^[61]

输入: 权重矩阵 $W \in \mathbb{R}^{m \times n}$ (其中 $m \leq n$), 学习率 η , 缩放因子 α , 动量系数 β_1, β_2 , 秩 r , 子空间更新周期 T

- 1 初始化一阶动量 $M_0 \in \mathbb{R}^{r \times n} \leftarrow 0$;
- 2 初始化二阶动量 $V_0 \in \mathbb{R}^{r \times n} \leftarrow 0$;
- 3 初始化步数 $t \leftarrow 0$;
- 4 **重复**
 - 5 计算梯度: $G_t \in \mathbb{R}^{m \times n} \leftarrow -\nabla_W \varphi(W_t)$;
 - 6 **如果** $t \bmod T = 0$ **则**
 - 7 SVD 分解: $U, S, V \leftarrow \text{SVD}(G_t)$;
 - 8 初始化投影矩阵: $P_t \leftarrow U_{[:,1:r]}$;
 - 9 **否则**
 - 10 保留上一步的投影矩阵: $P_t \leftarrow P_{t-1}$;
 - 11 将梯度投影到低秩子空间: $R_t \leftarrow P_t^T G_t$;
 - 12 **使用 Adam 在低秩子空间中更新:**
 - 13 $M_t \leftarrow \beta_1 \cdot M_{t-1} + (1 - \beta_1) \cdot R_t$;
 - 14 $V_t \leftarrow \beta_2 \cdot V_{t-1} + (1 - \beta_2) \cdot R_t^2$;
 - 15 偏差校正: $\hat{M}_t = M_t / (1 - \beta_1^t)$, $\hat{V}_t = V_t / (1 - \beta_2^t)$;
 - 16 计算更新步长: $N_t \leftarrow \hat{M}_t / (\sqrt{\hat{V}_t} + \epsilon)$;
 - 17 **投影回原始空间并更新参数:**
 - 18 $\tilde{G}_t \leftarrow P_t N_t$; // 恢复原始维度
 - 19 $W_{t+1} \leftarrow W_t - \eta \cdot \tilde{G}_t$;
 - 20 步数更新: $t \leftarrow t + 1$;
- 21 **直至** 满足收敛条件;
- 22 **返回** W_t

3.4 实验

3.4.1 参数设置

在本章的优化 GRPO 微调阶段中, 超参数配置如表3.1所示。所有实验均在 4× NVIDIA A100 80G GPU 上, 基于修改后的 TRL 框架和 vLLM 框架进行。对于微调和生成, 我们经实验, 选用附录 A.2提示词。

3.4.2 优化 GRPO 阶段实验结果

图 3.1 展示了强化微调阶段模型在整体训练过程中 reward 的变化趋势, 而图 3.4 则进一步拆解展示了各项 reward (Accuracy、Format、Length、Reasoning) 随训练步数演化的细节表现。

从整体趋势来看, 模型在前约 800 步内 reward 并不超过 base 模型, 说明此阶段策略尚未有效探索出可泛化的高质量输出模式, 强化信号仍处于低有效性区间。各项 reward 的动态变化反映出模型训练过程中多目标权衡机制的作用路径: 模型

表 3.1 阶段 1: GRPO 超参数设置

训练参数	值
Learning Rate	1e-6
LR Scheduler	Constant
Weight Decay	0.0
Gradient Clip	1.0
Optimizer	Adam w/ Galore ($\beta_1 = 0.9, \beta_2 = 0.95$)
Galore Update Freq.	128
Galore Rank	512
Batch Size	8
Training Epochs	4
Steps	3000
每组采样数 (G)	16
$\epsilon_{\text{low}}/\epsilon_{\text{high}}$	0.2 / 0.28
$\beta_{w_i,0}$	[0.25, 0.25, 0.45, 0.05]
T	500
a	5×10^{-7}
μ	0.2




图 3.3 阶段 1: GRPO 全过程奖励

首先优化结构与准确性 (Format + Acc)，随后逐步向逻辑长度 (Length) 与解释合理性 (Reasoning) 拓展。

具体地，随着训练推进，**Accuracy** 与 **Format** 两项 reward 值持续上升，并最终趋于收敛，整体接近 1。这说明模型已经基本掌握了选择正确选项与生成符合格式要求输出的能力。同时，这两项指标的方差逐步收敛，表明模型生成稳定性增强，输出质量趋于一致。

Length-based reward 在训练中期（约 800 ~ 1500 步）表现出轻微下降，这可能与模型在强化阶段更倾向于压缩无关内容以满足准确性指标有关。但在训练后期，其 reward 出现回升趋势，推测为模型生成的推理部分长度开始自然增长，形成较完整的逻辑链条，符合先短再长的结构适应性规律。

相比之下，**Reasoning relevance reward** 的出现较为滞后，仅在训练末期（2000 步后）才逐步产生有效奖励信号。这是由于该 reward 仅在一组输出中超过 60% 得到正确答案后才激活评分机制，因此初期参与优化的样本较少。此外，随着 acc




图 3.4 阶段 1: 四类奖励与方差对比图: (a) 准确率奖励, (b) 准确率方差, (c) 格式奖励, (d) 格式方差, (e) 长度奖励, (f) 长度方差, (g) 推理奖励, (h) 推理方差

达标样本比例上升, reasoning reward 的方差反而呈增长趋势, 表明虽然 reasoning reward 开始参与, 但模型生成的推理结构仍具有较大波动性, 存在合理性与一致性尚未完全统一的情况。

3.4.3 数据合成

为了引导模型生成具有结构化、可解释性的推理内容, 本文借鉴 DeepSeek R1 中的经验设计^[42], 在强化微调及数据合成阶段, 统一使用特定的输出模板: 以 ‘<|Assistant|>: <think>’ 作为模型响应的前缀, 从而强制模型从 ‘<think>’ 开始生成, 将回答过程显式地划分为 “思考阶段”。

通过这一策略, 我们不仅提升了 reasoning 部分的可解析性, 也为后续的自动评分与奖励设计 (如 Reasoning Relevance Reward) 奠定了结构基础。图 3.1 展示了一个典型的数据合成示例, 包含思考过程、最终选项及对应格式的完整输出, 更多样例可见附录 B。

为确保数据质量, 本文在生成完初始候选样本后, 采用两阶段筛选流程:

- 第一阶段使用 GPT-4o 模型对所有输出进行自动评分, 检查其结构完整性、逻辑合理性与答案准确性;




图 3.5 阶段 1: 合成的推理输出示例

- 第二阶段由人工对 GPT-4o 评分结果进行抽查和筛选，进一步检查样本。

最终，在共计 6501 条模型输出中，筛选得到 5307 条高质量样本，整体有效率
达到：

$$\frac{5307}{6501} \approx 81.63\%$$

这些数据样本将作为后续强化学习（GRPO）阶段的训练输入，用于构建具备完整推理过程的高质量训练数据集。

4 基于合成数据有监督微调与强化微调

4.1 视觉编码器

由于后续微调中设计模型的具体模块和接口，为方便下文阐述，我们首先介绍 JanusPro-7B 模型的视觉解码器部分：

4.1.1 SigLIP 编码器

SigLIP (Sigmoid loss for Language-Image Pre-training) 模型本质上是一种对比图文编码器^[66]，它继承了 CLIP 模型的双塔结构，即具有独立的图像编码器和文本编码器，两者通过对比学习训练以将对应的图像-文本对映射到相似的多模态嵌入空间。传统 CLIP 采用基于 Softmax 归一化的对比损失，将同一批次中的图文对进行全局比较，这要求极大的批大小和多卡通信以形成完整的相似度矩阵^[66]。SigLIP 引入 Sigmoid 损失函数，改为对每个图文对独立进行二元分类式的训练，从而避免了对全局负样本的显式归一化需求，降低了训练的内存和通信开销，并在小批量下取得更好的表现。这种改进使 SigLIP 在相同模型规模和数据下实现了比 CLIP 更高的图文匹配性能，例如在 ImageNet 零样本分类中 SigLIP 达到 84.5% 的准确率，大幅超越原始 CLIP。

Janus 模型中使用的 SigLIP-Large 编码器即基于 ViT-L/16，在输入图像尺寸 384×384 下产生 24×24 的小片网格 (patch) 特征。文本编码器通常为 Transformer 语言模型，将文本序列编码为语义向量。训练前，图像编码器可采用“锁定图像编码器调优 (Locked-Image Tuning, LiT)”策略：即先使用大规模有标签数据预训练图像编码器并冻结其权重，仅训练文本编码器以对齐图像语义空间^[66]。这种策略加上 Sigmoid 损失使得 SigLIP 能在有限计算资源下高效训练出高性能的对比模型。

SigLIP 在训练时使用图文对比学习，给定一批次包含 N 对图像 I_i 和文本 T_i ，首先通过图像编码器 $f(\cdot)$ 和文本编码器 $g(\cdot)$ 分别提取图像特征 $\mathbf{v}_i = f(I_i)$ 和文本特征 $\mathbf{t}_i = g(T_i)$ 。通常对特征向量进行 L_2 归一化，并设相似度由内积度量 $s_{ij} = \langle \mathbf{v}_i, \mathbf{t}_j \rangle$ 。传统 CLIP 的对比损失将每个图像 I_i 与所有文本进行 Softmax 归一化比较：

$$L_{\text{CLIP}}^{(i)} = -\log \frac{\exp(s_{ii}/\tau)}{\sum_{j=1}^N \exp(s_{ij}/\tau)}, \quad (4.1)$$

其中 τ 为温度参数^[51]。文本作为查询的对称损失形式类似，CLIP 的总损失是图像查询和文本查询两部分之和。上述损失要求计算完整的 $N \times N$ 相似度矩阵以获取分母中的归一化项。当 N 很大时计算和存储代价高，并需要在多卡训练时汇总所有特征^[66]。

SigLIP 将上述多类别分类问题转化为独立的二元分类问题。对于任意一对图像 I_i 和文本 T_j ，定义其标签 $y_{ij} = 1$ （匹配）当 $i = j$ ，否则 $y_{ij} = 0$ （不匹配）。SigLIP 使用 Sigmoid 函数 $\sigma(\cdot)$ 将相似度 s_{ij} 映射为匹配概率 $\hat{y}_{ij} = \sigma(s_{ij})$ ，并采用二元交叉熵损失：

$$L_{\text{SigLIP}} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N [y_{ij} \log \sigma(s_{ij}) + (1 - y_{ij}) \log(1 - \sigma(s_{ij}))], \quad (4.2)$$

其中仅当 $i = j$ 时第 i, j 项为正样本损失，其余为负样本损失^[66]。由于每对 (i, j) 的损失计算不依赖其他对的相似度，该方法不需要对整批样本进行 Softmax 归一化，也就避免了维护完整相似度矩阵。这使得 SigLIP 可以逐对地增量计算损失，极大降低内存开销和跨设备通信成本。经过如上对比训练后，SigLIP 图像编码器能够提取高维语义特征，在多模态嵌入空间中与对应文本特征对齐。

Janus 模型将预训练的 SigLIP 图像编码器用作视觉理解分支的特征提取器。在推理时，对于输入图像 I ，SigLIP 编码器提取得到其视觉特征映射 $v = f(I)$ 。与传统 CLIP 取全局图像的语义嵌入不同，Janus 利用 SigLIP 编码器最后一层的局部特征网格，即 ViT 的小片网格（patch）嵌入序列，作为图像表示。这些特征通常构成一个 $K \times K$ 的网格（例如 24×24 ），包含了图像的丰富语义信息和空间结构。Janus 首先将该网格展平成序列 $\{v_p\}_{p=1}^{K^2}$ ，然后通过理解适配器（Understanding Adaptor）将每个视觉特征投影到与大语言模型输入嵌入等维的向量 $\tilde{v}_p$ ^[5]。适配器由两层全连接网络构成，并且没有使用残差连接^[5]，公式可表示为 $\tilde{v} = W_2 \cdot \phi(W_1 v)$ ，其中 ϕ 为非线性激活函数。经过此映射，SigLIP 提取的视觉语义特征就嵌入到语言模型的词嵌入空间中，作为特殊的视觉词元序列与文本词元一同输入统一的 Transformer。大语言模型（Large Language Model, LLM）在多模态理解任务中会将这些视觉词元与文本提示共同处理，从中解码出高层语义信息并执行例如图像描述、问答等推理。由于 SigLIP 图像编码器提取的是抽象的语义特征（例如物体类别、属性等），这种高维特征表示非常适合作为大语言模型理解视觉内容的基础，为联合语义空间提供了高质量的视觉语义嵌入。

4.1.2 向量量化分词器 (VQ tokenizer)

Janus 模型的另一项关键组件是用于视觉生成的向量量化分词器，即向量量化图像编码器和解码器^[3]，其作用是在图像生成任务中将图像表示离散化为词元序列，使语言模型能够像处理单词一样处理图像信息。向量量化 (Vector Quantization, VQ) 编码器通常基于 VQ-VAE 或 VQ-GAN 结构^[3,53]。它由编码器、码本 (codebook) 和解码器三部分组成：编码器将输入图像压缩到低维的潜在表示，随后通过查找离散 codebook 将连续的潜在向量量化为离散索引序列，最后解码器将这些离散表示重建回原始图像。由于量化操作使图像表示成为离散词元，这些词元可用作生成式 Transformer 的“词汇”，从而将图像生成转化为序列生成问题^[53]。

VQ 编码器的工作流程如下：给定一幅输入图像 $x \in \mathbb{R}^{H \times W \times 3}$ ，首先由卷积神经网络 (或 ViT 等) 构成的编码器 $E(\cdot)$ 提取出一个低分辨率的连续隐表示 $z_e = E(x)$ 。 z_e 的空间尺寸通常是原图的 $1/d$ (d 为下采样因子，例如 Janus 使用的 VQ 编码器将图像下采样 16 倍^[5])，通道维度为 C 。这样 z_e 可以看作由若干 C 维向量组成的网格。设码本 (Codebook) $\mathcal{Z} = \{e_k\}_{k=1}^K$ 包含 K 个可学习的 C 维嵌入向量，每个向量称为一个离散代码。向量量化过程将 z_e 的每个位置向量 $z_e(i, j)$ 替换为在 $\mathcal{Z}$ 中最相似的一个嵌入：

$$k^* = \arg \min_k \|z_e(i, j) - e_k\|_2^2, \quad z_q(i, j) = e_{k^*}, \quad (4.3)$$

其中 z_q 表示量化后的隐表示， e_{k^*} 是选中的码本向量^[3]。同时记录离散索引 $\{k^*\}$ 作为该位置的词元表示。经过此操作，原来的连续隐表示 z_e 就被映射为一个离散索引矩阵 q (尺寸与 z_e 相同，每个位置存储码本索引)。这样，图像 x 被表示为一串离散码序列 k^* ，长度为隐表示的空间维数 (例如 $H/d \times W/d$)。这些离散码就是图像的“视觉单词”。解码器 $D(\cdot)$ 接收量化后的隐表示 z_q (或等价的索引序列经嵌入层映射回对应向量)，通过卷积或反卷积逐步上采样重建出图像 $\hat{x} = D(z_q)$ 。由于 z_q 中的成分都来自有限的码本集合 $\mathcal{Z}$ ，解码器被迫学会将这些离散“拼图块”组合还原成原图。

VQ 编码器的训练目标是使重建图像 $\hat{x}$ 尽可能逼近原始图像 x ，同时保证隐表示经过量化后损失的信息尽量少。典型的损失函数包括两部分^[3]

- 1) 重建损失 L_{recon} ：度量 $\hat{x}$ 与 x 的差异，例如像素级均方误差 (MSE) 或感知损失。它确保编码器-解码器能够重构图像主要内容：

$$L_{\text{recon}} = \|x - \hat{x}\|_2^2 \quad (4.4)$$

2) 向量量化损失：包括码本更新损失和承诺损失，以鼓励编码器输出贴近码本向量并确保码本得到充分利用：

- 码本更新损失 L_{codebook} ：将编码器输出 z_e 视作常量，直接优化码本使 e_{k^*} 逼近 $z_e(i, j)$ ： $L_{\text{codebook}} = \|\text{sg}[z_e(i, j)] - e_{k^*}\|_2^2$ ，其中 $\text{sg}[\cdot]$ 表示停止梯度，不对 z_e 求梯度。
- 承诺损失 L_{commit} ：为了防止编码器任意偏离码本中心，引入： $L_{\text{commit}} = \|z_e(i, j) - \text{sg}[e_{k^*}]\|_2^2$ ，并乘以权重系数 β 。该项鼓励 z_e 靠近选中的码本向量，从而“承诺”使用该离散表示。

总体损失为：

$$L = L_{\text{recon}} + L_{\text{codebook}} + \beta \cdot L_{\text{commit}} \quad (4.5)$$

。在实际实现中，常通过直接优化 L_{commit} 更新编码器参数，通过优化 L_{codebook} （或使用指数移动平均 EMA 策略）更新码本向量^[3]。解码器参数则主要由重建损失的梯度驱动调整。

Janus 将预训练好的向量量化编码器用作视觉生成分支的“词表提取器”^[5]。具体而言，Janus 采用了一个下采样因子为 16 的 VQ 模型作为生成编码器。该编码器将输入图像映射为 24×24 （对 384×384 图）的离散码索引网格，每个索引取值范围为码本大小（例如 $K = 8192$ ）^[5]。这样，每幅图像被表示成长度约 576 的词元序列。Janus 在训练时对于图像生成任务，会先用上述生成编码器将目标图像编码成离散词元序列 k_i 。然后通过生成适配器将这些图像词元对应的码本嵌入 e_{k_i} 映射到大语言模型的输入嵌入空间，作为一段特殊的“图像句子”输入到自回归 Transformer 中^[5]。在多模态生成训练中，大语言模型学习根据文本提示预测后续的图像词元序列。Janus 引入一个独立的图像生成输出头来预测离散图像词元（这一头在训练第一阶段随机初始化并学习，大语言模型本身的参数在初期保持冻结^[5]）。当生成阶段的 Transformer 输出一系列图像词元后，这些词元通过码本查找还原为向量 z_q ，再交给 VQ 解码器生成图像。

也就是说，Janus 的大语言模型模块负责输出图像的离散表示，而预训练的 VQ 解码器充当视觉解码器（Visual Decoder）将这些离散表示转译为最终图像。通过这种方式，Janus 将图像生成问题解耦成两个模块：由大语言模型预测“视觉词”序列，再由 VQ 解码器绘制图像。向量量化分词器确保了图像的表达既包含细粒度的局部信息，又因降维而具有全局一致性，这对高保真图像重建至关重要^[5]。相比直接让大语言模型生成像素值，离散码大大降低了生成的序列长度和难度，而且利用了 VQ-GAN 解码器的强大建模能力来保证视觉质量。

形式上，可将 Janus 的多模态生成过程表示为：给定文本提示 T ，大语言模型

生成后续词元序列 y_i ，其中包含文本词元和图像码元。当生成结束后，取出其中的图像词元序列 k_i ，通过解码器 D 得到生成图像 $\hat{x} = D(ek_i)$ 。即

$$\hat{x} = D\left(\{e_{k_i}\}_{i=1}^L\right), \quad \text{其中 } \{k_i\} \sim \text{LLM}(T) \quad (4.6)$$

在训练中，利用图像 L_{recon} 损失约束 $\hat{x}$ 逼近训练集目标图像，从而使大语言模型学会产生离散词元序列。由于采用了预训练的向量量化图像编码器（VQ-VAE/GAN）作为桥梁，Janus 的语言模型可以在保持统一自回归生成的框架下，同时胜任文本和图像的生成任务^[5]。

4.2 图像理解有监督微调（SFT）




图 4.1 阶段 2.1: 图像理解有监督微调

为了让模型在强化学习前获得一定的先验知识，避免探索空间过大，我们先使用 TQA 数据及上一轮合成的数据，共 $6501 + 5307 = 11808$ 条，进行图像理解的 SFT。具体而言，采用 Galore 算法（见 3.3）对模型的大语言模型部分进行 3 个 epochs 的微调，在显著减少显存占用的同时，让模型更倾向产生符合任务需求的回答，并注入适量的领域相关知识，从而使后续的强化学习阶段更加稳定高效。

通过上述有监督训练，JanusPro-7B 将逐步学习科学问答任务的映射关系：从给定的问题（包含文字和图像）预测出正确的答案（以及可能的解释）。SFT 可以

算法 4.1: 有监督微调 (SFT) 算法

- 1 首先, 使用原始数据和上一轮的合成数据, 对 JanusPro-7B 模型的大语言模型部分进行 3 轮 SFT (Supervised Fine-Tuning) 监督微调 4.1, 以提升其基础生成能力。随后使用优化的 GRPO 算法进行进一步强化微调, 从而增强模型在复杂推理任务中的表现^[55]。
- 输入:** 标注训练数据集 $D = \{(x^{(i)}, y^{(i)})\}$, 初始参数 θ_0 , 学习率 η , 总轮数 N , batch 大小 B
- 输出:** 微调后的模型参数 θ
- 2 初始化: $\theta \leftarrow \theta_0$;
- 3 **对于** $epoch = 1$ **转到** N **进行**
- 4 **对于每个** $mini\text{-}batch \{(x_j, y_j)\}_{j=1}^B \subset D$ **进行**
- 5 **对于** $j = 1$ **转到** B **进行** 前向传播: $\hat{y}_j = f_\theta(x_j)$;
- 6 计算平均损失: $\mathcal{L} = -\frac{1}{B} \sum_{j=1}^B \log P_\theta(y_j | x_j)$;
- 7 反向传播, 更新模型参数: $\theta \leftarrow \theta - \eta \cdot \nabla_\theta \mathcal{L}$;
- 8 **返回** θ

充分利用现有标注数据的知识, 能快速提升模型在目标任务上的基本准确率。这一步微调得到的模型命名为 JanusProFT v1。

4.3 图像生成与理解联合的有监督微调

上一步的有监督微调使用阶段一合成的数据, 有效增强了模型对复杂图像及其相关逻辑推理的理解能力。在此基础上, 我们进一步开展视觉-文本联合的监督微调 (SFT), 以全面提升模型的图文理解能力及图像生成质量。

4.3.1 图片描述数据集合成

为了合成训练所需的图文对数据集, 我们首先利用上一步已具备较强理解能力的 JanusProFT v1 模型, 对图像进行多轮描述生成。具体地, 我们为每张图像构造 N 条不同提示语, 引导模型生成多样化的图像描述。随后, 将每条描述与变化后题目内容进行拼接, 并重新输入 JanusProFT v1 模型进行 M 次问答测试。若模型基于该描述能够以高于 90% 准确回答变化后的问题, 则视该描述在该任务下为有效语义注释, 并将其与对应图像组成图文对, 加入图片描述合成数据集。

我们对题目的变化主要以以下形式进行:

- 1) 更改选项顺序
- 2) 在题目前后增加少量无关内容, 例如: "Here is the question for you: "。

随后, 类似 3.4.3, 使用 GPT-4o 和人工筛选, 最终筛选得 ($N = 3, M = 10$)

13743 条高质量样本，整体有效率达到：

$$\frac{13743}{6501 \times 3} \approx 70.5\% \quad (4.7)$$

Stage 2.2 Description Generation




图 4.2 阶段 2.2: 图像描述数据的生成与筛选

4.3.2 联合有监督微调




图 4.3 阶段 2.3: 图像理解有监督微调

在本阶段，我们首次解冻模型的理解适配器、生成适配器、文本生成头、图像生成头部分以及大语言模型模块，以较小的学习率对整个模型进行联合微调，

图 4.4 引用自^[5]。数据集由以下三部分组成：

- 1) 从原始 TQA 数据集的 6501 题中随机抽取的 1000 题，对题目文本进行随机的变换。
- 2) 第一阶段合成的数据集中随机抽取 4500 题，对题目文本进行随机的变换。
- 3) 上一阶段获得的图像描述数据集，共 13743 条，对题目文本进行随机的变换。
- 4) 由上一阶段描述与第一阶段合成数据集的 QA 部分拼接而成的纯文本数据集，随机抽取 8000 条，对题目文本进行随机的变换。

即总共 5500 条 VQA 数据，8000 条纯文本数据，13743 条图像描述数据。数据比例大约为 2 : 3 : 5，该阶段微调后得到的模型为 JanusProFT v2。

4.4 引入图像生成奖励的 GRPO




图 4.4 阶段 2.4: 图像生成的 GRPO

为使模型能对相关知识生成更合适的配图，我们在强化学习部分引入图像生成奖励。具体地：我们首先重新冻结理解适配器、生成适配器、文本生成头、图像生成头部分，仅保留大语言模型模块。使用合成的图像描述数据集进行训练。

对于一条描述，模型一批次生成 G 张图像，使用该合成图像替代 VQA 数据集的原始图像，对问题文本做随机变换。使用 JanusProFT v1 模型对拼接的图文提问进行 K 回答，回答正确率作为奖励值 reward_0 ，生成图像与原图的归一化 L_2 距离作为奖励值 reward_1 。每张输出图片的总体奖励为：

$$\text{reward}_{V_i} = \alpha \cdot \text{reward}_0 + (1 - \alpha) \cdot \text{reward}_1 \quad (4.8)$$

为了在训练初期更多地激励模型输出与原图的一致性，训练末期更多地考虑图像

语义, $\alpha = \epsilon T$, T 为训练的步数。GRPO 算法部分采用了 3.2 部分的算法, 但 KL 散度项的系数 $\beta = 0$ 。

4.5 实验

本节介绍并分析本研究在多模态任务上的实验设置及结果。表 4.1 列出了各阶段微调所使用的主要超参数, 其中“数据比例”表示多模态理解数据、纯文本数据与图像生成数据三者之间的混合比例, 参考了^[5]的配置, 以兼顾模型的理解与生成能力。从表 4.2 可见, 模型在每个阶段的性能均有所提升, 尤其在理解与生成任务间存在一定程度的正向迁移: 对理解任务的训练可促进生成能力的提升, 而生成任务的优化亦能反哺理解性能。

我们对模型性能进行了系统评估。实验数据显示, 基础模型在 TQA 测试集上的初始准确率为 62%, 经过第一阶段(理解 SFT)微调后, 这一指标跃升至 78%。说明该阶段通过大量多模态理解与文本推理任务的训练, 显著增强了模型的推理能力。第二阶段(联合 SFT)在保持理解能力的同时, 重点引入了图像生成训练数据。结果显示, 该阶段不仅实现了生成性能的提升, 还使 TQA 准确率进一步提高到 79.3%, ScienceQA 数据集上的表现也获得同步改善。

在阶段 2.3 (GRPO) 的强化微调中, 虽然准确率增幅相对较小(从 79.3% 到 83.7%), 但该现象具有重要意义: 生成训练对理解推理能力的提升具有持续促进作用。更值得关注的是, 模型在一致性比率 (CR) 和解释合理性 (Rationality Score) 等指标上均呈现稳定上升趋势, 这表明:

- 模型对输入扰动的鲁棒性显著增强
- 输出解答的逻辑性和条理性得到实质性改善
- 多任务协同训练产生了正向迁移效应

模型初始的生成质量 (FID 约 15.93) 较高, 说明与真实图像分布存在明显差异。经过第一阶段的理解 SFT, 生成指标仅略有改善; 而在第二阶段(联合 SFT)中, 大量引入图像生成数据配合理解任务, 使 FID 降至约 10.47, CLIP Score 从 0.62 提升至 0.73, 表明模型能够生成更贴近所需语义的图像。第三阶段 (GRPO) 则在生成环节做了强化微调, 使 FID 略有进一步降低, VQA 再验证指标也跃升至 57%, 侧面表明生成的图像能更好地服务下游多模态问答场景。

进一步地, 模型在未见过的 ScienceQA 测试集上也能取得与 TQA 相当的表现, 这说明本研究提出的多阶段微调范式至少具备良好的领域内领域泛化能力。尤其在理解 SFT 与联合 SFT 阶段中, 多模态与文本数据的组合训练能够帮助模型习得

较为稳健的视觉-语言对齐与推理能力，即使切换到新的 QA 场景，性能依旧保持在较高水准。

综上所述，三个微调阶段在理解与生成任务上各有侧重又相互促进，验证了“多模态理解 + 文本推理 + 图像生成”联合训练策略的有效性；而 GRPO 进一步强化了生成质量的同时，也为模型的解释一致性提供了额外助力。后续可在更多不同领域的数据集上进一步验证此训练框架的适应性和通用性。

表 4.1 阶段 2：SFT 与优化 GRPO 的超参数设置

SFT		联合 SFT		优化 GRPO	
Learning Rate	2e-5	Learning Rate	1e-5	Learning Rate	1e-6
LR Scheduler	Constant	LR Scheduler	Constant	LR Scheduler	Constant
Weight Decay	0.0	Weight Decay	0.0	Weight Decay	0.0
Gradient Clip	1.0	Gradient Clip	1.0	Gradient Clip	1.0
Optimizer	Adam w/ Galore ($\beta_1 = 0.9, \beta_2 = 0.95$)	Optimizer	Adam w/ Galore ($\beta_1 = 0.9, \beta_2 = 0.95$)	Optimizer	Adam w/ Galore ($\beta_1 = 0.9, \beta_2 = 0.95$)
Galore Update Freq.	128	Galore Update Freq.	128	Galore Update Freq.	128
Galore Rank	256	Galore Rank	512	Galore Rank	512
Batch Size	64	Batch Size	64	Batch Size	32
Training Epochs	3	Training Epochs	3	Training Epochs	4
Steps	555	Steps	1278	Steps	3000
		数据比例	2:3:5	每组采样数 (G)	4
				$\epsilon_{low} / \epsilon_{high}$	0.2 / 0.28
				β	0
				ϵ	1.25e-4

表 4.2 在 TQA 和 ScienceQA 上三个阶段的性能对比

指标	TQA				ScienceQA			
	基础模型	理解 SFT	联合 SFT	GRPO	基础模型	理解 SFT	联合 SFT	GRPO
(1) 理解性能评价指标								
Acc(%)	62.0	78.0	79.3	83.7	71.2	76.1	78.0	85.8
CR(%)	55.9	69.2	72.9	74.5	52.6	67.0	70.4	79.3
Rationality Score	1.2	3.4	3.6	3.8	1.4	3.2	3.5	3.7
(2) 生成性能评价指标								
FID	15.93	14.31	10.47	10.27	16.12	14.52	11.05	10.78
CLIP Score	0.62	0.67	0.73	0.75	0.60	0.65	0.70	0.73
VQA 再验证 (%)	32	35	41	57	28	32	37	52



微调前



SFT 联合微调后



GRPO 微调后

图 4.5 图像在三个微调阶段的生成效果对比：上为原始模型，中为联合 SFT 后，下为强化微调 GRPO 后

5 实验

5.1 改进 GRPO 与原始算法的性能对比

为验证本研究所提出的 GRPO 改进机制的有效性，我们设计了一组消融实验，对比优化后的 GRPO 与原始 GRPO 算法在相同环境下的表现。所有实验均保持相同的 reward 函数设定，并在此基础上，移除我们提出的以下关键机制：

- **方差加权机制**：用于对不同策略样本之间的偏差进行自适应调整；
- **词元级奖励机制**：以词元（Token）粒度建模局部生成质量，提供更细粒度的优化信号^[43]；
- **非线性推理长度奖励**：鼓励模型在合理长度范围内进行高质量推理；
- **动态采样机制**：根据 reward 分布动态调整采样温度，提高样本多样性与训练稳定性^[43]。

图 5.1 展示了优化 GRPO 与原始 GRPO 在连续 3000 步训练过程中的 reward 收敛曲线对比结果。可以观察到：




图 5.1 优化 GRPO 与原始 GRPO 的收敛曲线对比

- **收敛速度更快**：优化 GRPO 在前 1000 步内 reward 提升显著，表明其能更快捕捉高质量策略方向；
- **稳定性更高**：在中后期训练阶段，原始 GRPO 的 reward 存在较大波动，而改进后算法整体曲线更为平滑，波动幅度明显减小；当然，下面是续写建议：
- **最终性能更优**：最终的奖励略微高于原始版本，说明多机制协同优化对于整体性能提升具有正向增益。尽管从曲线上看并未收敛，但考虑到 GRPO 算法极易模式崩塌，本方法在长时间训练下依然能够保持较为稳定的训练过程，未出现明显的性能退化或奖励骤降。这表明多机制协同不仅提升了最终性能，还在一定程度上增强了模型的鲁棒性和泛化能力，为后续更大规模或更

复杂任务的训练提供了有益的参考。

5.2 图像生成与理解统一模型的协同促进效应

为验证在 JanusPro 的自回归图像生成与理解统一架构下，图像生成与理解任务之间的协同促进效应，我们分别对基础模型进行了两组有监督微调实验：一组仅使用 1 万条纯图像生成数据（从图像描述数据集中随机抽取），另一组仅使用 1 万条纯图像理解数据（由 3000 条图像描述数据和 7000 条 VQA 数据随机组成）。通过对比微调前后模型在 TQA 和 ScienceQA 两个数据集上的理解与生成性能，分析不同任务数据对模型整体能力的影响。

表 5.1 纯图像生成数据训练后的性能

指标	TQA		ScienceQA	
	基础模型	生成 SFT	基础模型	生成 SFT
(1) 理解性能评价指标				
Acc(%) ↑	62.0	67.7	71.2	73.4
CR(%) ↑	55.9	61.5	52.6	58.5
Rationality Score ↑	1.20	2.00	1.40	2.10
(2) 生成性能评价指标				
FID ↓	15.93	9.50	16.12	10.00
CLIP Score ↑	0.62	0.75	0.60	0.72
VQA 再验证 (%) ↑	32	39	28	35

表 5.2 纯图像理解数据训练后的性能

指标	TQA		ScienceQA	
	基础模型	理解 SFT	基础模型	理解 SFT
(1) 理解性能评价指标				
Acc(%) ↑	62.0	80.0	71.2	78.5
CR(%) ↑	55.9	74.0	52.6	71.5
Rationality Score ↑	1.2	3.9	1.4	3.8
(2) 生成性能评价指标				
FID	15.93	15.43	16.12	16.53
CLIP Score ↑	0.62	0.67	0.60	0.61
VQA 再验证 (%) ↑	32	38	28	34

从表5.1和表5.2可以看出，在 JanusPro 统一架构下，图像生成与理解任务的训练不仅能够显著提升各自的核心能力，还对另一任务表现产生了积极影响。

具体而言，仅用图像生成数据进行微调时，模型在生成相关指标（如 FID、CLIP Score）上取得了大幅提升，同时在理解相关指标（如 Acc、CR、Rationality Score）上也有一定程度的提升，验证了生成任务的训练能够促进模型的理解能力^[67,8]。

而在仅用图像理解数据进行微调时，模型在理解相关指标上获得了显著提升，同时在生成相关指标上总体上也有小幅提升，表明理解任务的训练同样能够一定程度地反哺生成能力。

该实验验证了在统一模型架构下，图像生成与理解任务之间存在协同促进效应^[67,8]。即使在单任务微调场景下，模型也能通过共享的表征和参数迁移，实现跨任务的能力提升。这一发现为多模态任务的统一建模和多任务协同优化提供了有力的实验支持。

6 总结与展望

本文针对多模态大模型在科学问答与图像生成场景中的应用需求, 围绕 Janus-Pro 模型展开了系统的研究与改进。通过对现有多模态模型发展现状的分析。首先, 本文创新性地设计了一种“SFT 预热 → 强化学习优化 → 自反馈推理强化”的递进式训练范式^{4, 3}有效融合了有监督微调 (SFT) 与强化学习 (RL) 的优势, 显著增强了模型在科学问答与图像生成任务上的性能。其次, 通过理解与生成任务的联合优化及交叉自反馈监督机制, 本文提出的 JanusPro-SciQA 模型不仅有效提高了模型的综合能力, 更验证了任务之间协同增强的可行性。实验结果显示, 采用该训练范式的模型无论在理解任务还是生成任务上都取得了较为显著的性能增益, 并在 ScienceQA、TQA 这类科学问答数据集上展现出更好的领域内泛化能力和解释性。主要工作与结论可概括如下:

- 1) **在多模态统一模型上融理解与生成双任务:** 通过统一架构和数据处理流程, 模型能够同时掌握图像理解和图像生成能力。实验表明, 理解微调与生成微调之间存在正向迁移, 能够相互促进提升, 打破了传统模块化设计下“各自为战”的局限。
- 2) **改进 GRPO 算法以适应多模态强化微调:** 本文面向多模态场景对 GRPO 进行了若干改进, 包括方差加权机制、词元级奖励以及动态采样策略等, 从而在高维连续空间与离散文本空间间进行更稳健的策略优化。相比原始 GRPO, 改进算法在收敛速度、对奖励噪声的稳健性以及后期训练稳定性方面均取得显著提升。
- 3) **二阶段训练范式的有效性:** 通过将有监督微调和强化微调合理分阶段进行, 模型得以先获得对任务的基本认知, 再利用强化学习进一步对齐模型行为。特别是在科学问答场景, 二阶段微调机制能够更好地引导模型生成符合逻辑、可解释性更高的答案, 并在图像生成质量上取得显著提高。
- 4) **在科学场景下的广泛适用性:** 虽然主要实验在 ScienceQA、TQA 数据集上展开, 结果表明所得模型具备较高的领域内能力, 也表明二阶段微调范式在需要图文并茂解释的教学或科普领域具有较大潜力。

尽管本文取得了一定的进展, 但仍然存在一些不足与待解决的问题。例如, 现有微调方法对长序列生成与高分辨率图像生成的效率和质量仍然有一定的局限性; 强化学习过程中奖励设计的精细化和人类反馈的高效利用也尚待探索; 此外, 自

动生成的推理数据仍存在一定噪声，如何进一步提高数据质量也值得深入研究。

展望未来，多模态统一模型的发展具有广阔前景。一方面，可以尝试更大规模、更高效的统一模型训练，以期进一步提高模型的泛化能力和任务适应性；另一方面，微调机制与强化学习的整合可以进一步深入，例如探索更先进的策略优化算法或更高效的人类反馈机制。此外，如何将本文提出的方法拓展至其他领域，如医疗诊断、法律推理、程序生成等应用场景，进一步推动多模态大模型的实际应用价值，也是未来值得研究的重要方向。

参考文献

- [1] HUANG S, DONG L, WANG W, et al. Language is not all you need: Aligning perception with language models[J]. NeurIPS, 2023, 36: 72096-72109.
- [2] TIAN K, JIANG Y, YUAN Z, et al. Visual autoregressive modeling: Scalable image generation via next-scale prediction[J]. NeurIPS, 2024, 37: 84839-84865.
- [3] VAN DEN OORD A, VINYALS O, et al. Neural discrete representation learning[J]. NeurIPS, 2017, 30.
- [4] SUN Q, YU Q, CUI Y, et al. Emu: Generative pretraining in multimodality[A]. 2023.
- [5] WU C, CHEN X, WU Z, et al. Janus: Decoupling visual encoding for unified multimodal understanding and generation[A]. 2024.
- [6] CHEN X, WU Z, LIU X, et al. Janus-pro: Unified multimodal understanding and generation with data and model scaling[A]. 2025.
- [7] LIU H, LI C, WU Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2023, 36: 34892-34916.
- [8] JIN Y, XU K, CHEN L, et al. Unified language-vision pretraining in llm with dynamic discrete visual tokenization[A]. 2023.
- [9] KEMBHAVI A, SEO M, SCHWENK D, et al. Are you smarter than a sixth grader? textbook question answering for multimodal machine comprehension[C]//CVPR. 2017: 4999-5007.
- [10] CADENE R, BEN-YOUNES H, CORD M, et al. Murel: Multimodal relational reasoning for visual question answering[C]//CVPR. 2019: 1989-1998.
- [11] LU P, MISHRA S, XIA T, et al. Learn to explain: Multimodal reasoning via thought chains for science question answering[C]//NeurIPS: Vol. 35. 2022: 13010-13023.
- [12] 蔡瑞祥, 赵书良, 何家瑶. 基于图文知识融合的常识问答模型[J]. 计算机科学: 1-13.
- [13] 胡景畅, 强鹏鹏, 谭红叶, 等. 基于图文理解增强的教科书视觉问答方法[J]. 山西大学学报(自然科学版): 1-10.
- [14] 王鹏. 文本到图像生成方法的研究进展[J]. 信息技术, 2024(07): 148-159.
- [15] GE Y, ZHAO S, ZHU J, et al. Seed-x: Multimodal models with unified multi-granularity comprehension and generation[A]. 2024.
- [16] XIE J, MAO W, BAI Z, et al. Show-o: One single transformer to unify multimodal understanding and generation[A]. 2024.
- [17] LI Z, LI H, SHI Y, et al. Dual diffusion for unified image generation and understanding[A]. 2025.
- [18] LIU H, YAN W, ZAHARIA M, et al. World model on million-length video and language with ringattention[A]. 2024.
- [19] ZHOU C, YU L, BABU A, et al. Transfusion: Predict the next token and diffuse images with one multi-modal model[A]. 2024.

- [20] WANG C, LU G, YANG J, et al. Illume: Illuminating your llms to see, draw, and self-enhance [A]. 2024.
- [21] BULKA A, WILNER E K, WU Z, et al. Chameleon: Mixed-modal early-fusion foundation models[A]. 2024.
- [22] DONG R, HAN C, PENG Y, et al. Dreamllm: Synergistic multimodal comprehension and creation[C]//ICLR. 2024.
- [23] TONG S, FAN D, ZHU J, et al. Metamorph: Multimodal understanding and generation via instruction tuning[A]. 2024.
- [24] WU S, FEI H, QU L, et al. Next-gpt: Any-to-any multimodal llm[A]. 2023.
- [25] TEAM G, ANIL R, BORGEAUD S, et al. Gemini: a family of highly capable multimodal models [A]. 2023.
- [26] QU L, ZHANG H, LIU Y, et al. Tokenflow: Unified image tokenizer for multimodal understanding and generation[A]. 2024.
- [27] WU Y, ZHANG Z, CHEN J, et al. Vila-u: a unified foundation model integrating visual understanding and generation[A]. 2024.
- [28] CHEN X, WU Z, LIU X, et al. Janus-pro: Unified multimodal understanding and generation with data and model scaling[A]. 2025.
- [29] LI J, LI D, SAVARESE S, et al. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models[C]//ICML. 2023: 19730-19742.
- [30] RAMESH A, DHARIWAL P, NICHOL A, et al. Hierarchical text-conditional image generation with clip latents[A]. 2022.
- [31] WANG X, ZHANG X, LUO Z, et al. Emu3: Next-token prediction is all you need[A]. 2024.
- [32] FOUNDATION P S. Python 3.11 documentation: Lexical analysis[Z]. 2023.
- [33] WEI T, CHEN D, ZHOU Y, et al. Enhancing mmdit-based text-to-image models for similar subject generation[A]. 2024.
- [34] MA Y, LIU X, CHEN X, et al. Janusflow: Harmonizing autoregression and rectified flow for unified multimodal understanding and generation[A]. 2024.
- [35] LU J, CLARK C, LEE S, et al. Unified-io 2: Scaling autoregressive multimodal models with vision, language, audio, and action[A]. 2023.
- [36] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//NeurIPS: Vol. 33. 2020: 1877-1901.
- [37] LI J, SU H, ZHU J, et al. Textbook question answering with memory networks under instructor guidance[C]//CVPR. 2018: 3655-3663.
- [38] DAI W, LI J, LI D, et al. Instructblip: Towards general-purpose vision-language models with instruction tuning[C]//NeurIPS: Vol. 36. 2023: 6933-6950.
- [39] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[C]//NeurIPS: Vol. 35. 2022: 27730-27744.
- [40] SHAO Z, WANG P, ZHU Q, et al. Deepseekmath: Pushing the limits of mathematical reasoning

- in open language models[A]. 2024.
- [41] RAMESH S S, HU Y, CHAIMALAS I, et al. Group robust preference optimization in reward-free rlhf[C]//NeurIPS: Vol. 37. 2024.
 - [42] AI D. Deepseek-rl: Incentivizing reasoning capability in llms via reinforcement learning[A]. 2025.
 - [43] YU Q, ZHANG Z, ZHU R, et al. Dapo: An open-source llm reinforcement learning system at scale[A]. 2025.
 - [44] WILLIAMS M. Multi-objective reinforcement learning from ai feedback[A]. 2024.
 - [45] SHARMA H, JALAL A S. A survey of methods, datasets and evaluation metrics for visual question answering[J]. Image and Vision Computing, 2021, 116: 104327.
 - [46] ROSS C, HALL M, ROMERO-SORIANO A, et al. What makes a good metric? evaluating automatic metrics for text-to-image consistency[A]. 2024.
 - [47] LAI C, SONG S, MENG S, et al. Towards more faithful natural language explanation using multi-level contrastive learning in vqa[A]. 2023.
 - [48] HEUSEL M, RAMSAUER H, UNTERTHINER T, et al. Gans trained by a two time-scale update rule converge to a local nash equilibrium[C]//NeurIPS: Vol. 30. 2017.
 - [49] KYNKÄÄNNIEMI T, KARRAS T, AITTALA M, et al. The role of imagenet classes in fréchet inception distance[C]//ICLR. 2023.
 - [50] BI X, CHEN D, CHEN G, et al. Deepseek llm: Scaling open-source language models with longtermism[A]. 2024.
 - [51] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//ICML: Vol. 139. 2021: 8748-8763.
 - [52] LI J, LI D, XIONG C, et al. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation[C]//ICML: Vol. 162. 2022: 12763-12779.
 - [53] ESSER P, ROMBACH R, OMMER B. Taming transformers for high-resolution image synthesis [C]//CVPR. 2021: 12873-12883.
 - [54] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//CVPR. 2022: 10684-10695.
 - [55] ZIEGLER D M, STIENNON N, WU J, et al. Fine-tuning language models from human preferences[A]. 2019.
 - [56] ZHANG J, KIM J, O'DONOGHUE B, et al. Sample efficient reinforcement learning with reinforcement[A]. 2020.
 - [57] SUTTON R S, MCALLESTER D, SINGH S, et al. Policy gradient methods for reinforcement learning with function approximation[C]//NeurIPS: Vol. 12. 1999.
 - [58] WILLIAMS R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning[J]. Machine learning, 1992, 8: 229-256.
 - [59] SCHULMAN J, LEVINE S, ABBEEL P, et al. Trust region policy optimization[C]//ICML: Vol. 37. 2015: 1889-1897.

- [60] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[A]. 2017.
- [61] ZHAO J, ZHANG Z, CHEN B, et al. Galore: Memory-efficient llm training by gradient low-rank projection[A]. 2024.
- [62] XIE T, GAO Z, REN Q, et al. Logic-rl: Unleashing llm reasoning with rule-based reinforcement learning[A]. 2025.
- [63] ZHANG J, ZUO C. Grpo-lead: A difficulty-aware reinforcement learning approach for concise mathematical reasoning in language models[A]. 2025.
- [64] ZENG W, HUANG Y, LIU Q, et al. Simplerl-zoo: Investigating and taming zero reinforcement learning for open base models in the wild[A]. 2025.
- [65] SCHULMAN J. Approximating kl divergence[Z]. 2020.
- [66] ZHAI X, MUSTAFA B, KOLESNIKOV A, et al. Sigmoid loss for language image pre-training [C]//ICCV. 2023: 11975-11986.
- [67] NIU Y, NING M, ZHENG M, et al. Wise: A world knowledge-informed semantic evaluation for text-to-image generation[A]. 2025.

附录 A 提示词

A.1 GPT-4o 提示词

System:

You are a strict and professional evaluator.
Please carefully read the provided question
and the answer with its explanation.

We use three dimensions to evaluate the explanation:

- (1) Logic Consistency
- (2) Clarity
- (3) Relevance

Each dimension is rated from 1 to 5. Please reference the scale below:

=====

Logic Consistency:

- 1 - Major logical flaws or contradictions.
- 2 - Partially logical but with noticeable oversights.
- 3 - Mostly logical, some minor flaws or unfounded jumps.
- 4 - Generally sound logic with small room for improvement.
- 5 - Completely coherent with no apparent logical gaps.

Clarity:

- 1 - Very unclear or confusing writing; hard to follow the reasoning.
- 2 - Basic meaning is discernible, but significant ambiguity.
- 3 - Mostly understandable with some possible ambiguities.
- 4 - Clear and concise, minimal ambiguity.
- 5 - Extremely clear, well-structured, and easy to understand.

Relevance:

- 1 - Largely off-topic or unrelated to the question and answer's main points.
- 2 - Partly relevant but contains considerable extraneous content.
- 3 - Mostly relevant with slight deviations.
- 4 - Very relevant, only minor unnecessary details.
- 5 - Focused precisely on the question and answer, no digression.

Overall Score:

- An integer 1-5 representing the overall rationality of the explanation.

=====

After reading the question and the answer (with explanation),
provide a JSON output with the following structure (no extra text):

```
{
  "LogicConsistencyScore": <integer 1-5>,
  "ClarityScore": <integer 1-5>,
  "RelevanceScore": <integer 1-5>,
  "OverallScore": <integer 1-5>,
  "Comments": "<short reason>"
}
```

A.2 数据合成提示词

System:

You are a helpful language and vision assistant.

You are able to understand the visual content that the user provides,
and assist the user with a variety of tasks using natural language.

You are given a science question with multiple choices, a passage,
and an image.

Your task is to thoroughly reason through it step by step.

Present your logic within <think>...</think>.

Identify the correct choice by referring to its 0-based index,

exactly matching the given choices.

Follow this exact response format (in order, with labels exactly as shown):


<think>[Detailed, step-by-step reasoning]</think>

<choice text>: [Copy or summarize the correct choice text]

<choice index>: [0-based choice index; first is 0, not 1.]

Make sure all three sections are present, in the specified order.

附录 B 更多合成数据




Question: Which muscle separates the chest from the abdomen?

Options: 0) Diaphragm 1) Spleen
2) Neck 3) Thymus

Reasoning: To answer the question of which muscle separates the chest from the abdomen, we can refer to the anatomical structure depicted in the image. The diaphragm is explicitly labeled as the muscle fulfilling this function. Understanding the role of the diaphragm is essential; it contracts and relaxes to allow respiration and delineates the thoracic cavity from the abdominal cavity. Therefore, identifying this structure among the given options will lead us to the correct answer.

Answer: 0

Image Description: The image illustrates the human lymphatic system, highlighting various components. At the top, there is a representation of the neck region with cervical lymph nodes labeled as 'Neck.' The thymus is depicted centrally, at the upper chest area, where it is connected to various lymph vessels. Below the thymus, the diaphragm is labeled with a description noting it as the muscle that separates the chest from the abdomen. To the left, the spleen is indicated, and to the right, the liver is shown. Along the sides of the illustration, there are also labels indicating the armpit (axillary) lymph nodes and groin (inguinal) lymph nodes, along with vascular structures depicted in purple illustrating the network of lymph vessels.



Question: Which label shows the Centrosome?


Options: 0) C 1) D
2) W 3) M

Reasoning: To determine which label represents the centrosome in the diagram, we begin by identifying the various structures illustrated in the cell. The centrosome, crucial for organizing microtubules during mitosis, typically consists of two

perpendicular centrioles situated near the nucleus. In the diagram, the labels associated with recognizable organelles are listed alongside their respective structures. By carefully examining these labels, it is clear that label 'D' is positioned near the central area of the cell and is likely representing the centrosome. The other labels (C, W, M) correspond to either the nucleus or other organelles and do not indicate the location of the centrosome. Hence, selecting label 'D' as the representation of the centrosome is consistent with how these structures are typically depicted in cell biology.

Answer: 1

Image Description: The image depicts a colorful diagram of a cell, detailing various cellular structures labeled with corresponding letters. In the center, there is a prominent red structure that represents the nucleus, characterized by its circular shape and distinct boundary. Surrounding the nucleus, several other organelles are illustrated. The centrosome, a critical structure for cell division and composed of two centrioles, is located towards the right of the nucleus near labeled structure 'D'. To the left, there is a large blue organelle which likely represents the endoplasmic reticulum, and other organelles such as mitochondria and chloroplasts also appear in various positions. The labels 'C', 'D', 'W', and 'M' correspond to different organelles, with the centrosome specifically identified under label 'D'. The diagram is presented in a clear, educational format to aid in the understanding of cellular anatomy.




Question: In how many figures are there identical copies of DNA within 1 cell?

Options: 0) 4 1) 3
2) 2 3) 6

Reasoning: To answer the question, we need to assess how many identical copies of DNA are present in the cell at each stage displayed in the figures. 'Identical copies of DNA' in this context refers to replicated strands of DNA within a single cell. Initially, each cell contains one set of DNA before replication. Upon replication, we see a doubling of these strands. Therefore, right after replication, there are four total DNA strands present (two strands of each color: two red and two blue) in the replicating cell. After mitosis, the two resulting diploid cells will each contain one strand of each color, not adding to the total in the original cell. Hence, it is correct to say that there are four identical copies of DNA after the replication process in a single cell.

Answer: 1

Image Description: The image depicts a sequence of events in cell division, specifically highlighting DNA replication and mitosis. There are three main stages illustrated: 1) Initial cell with two strands of DNA represented by colored strands (one red and one blue) inside a cell membrane. 2) Following DNA replication, where both DNA strands have been duplicated, resulting in two red and two blue strands, still within a cell membrane. 3) Mitosis, where the chromosomes (red and blue strands) align and are separated, before two new cells are formed, each with one red and one blue DNA strand. In total, the final images show two distinct diploid cells, each carrying identical copies of the original DNA strands. Notably, at the stage of DNA replication, the total number of DNA strands present amounts to four (two original strands each producing a copy).



Question: How many phases before telophase?

Options: 0) 5 1) 4
2) 7 3) 6

Reasoning: To determine how many phases occur before telophase, we need to look at the numbered phases in the image. Telophase is labeled as phase 6. Therefore, to find out how many phases occurred before telophase, we count from phase 1 to phase 5, as telophase itself is phase 6. This results in a total

of 5 phases that occur before telophase.

Answer: 0

Image Description: The image illustrates the process of cell division, specifically mitosis, detailing several key phases. At the top, the stages are labeled from 1 to 6. The first phase is Interphase (1), showing a cell with a large nucleus and visible centrosomes. The second phase is Prophase (2), where chromatin condenses into visible chromosomes, and spindle fibers begin to form. The third phase, Pro-Metaphase (3), depicts the chromosomes attached to the spindle fibers at the centromeres. The fourth phase shows Metaphase (4), where chromosomes are aligned at the cell's equatorial plane. The fifth phase is Anaphase (5), with chromosomes pulled apart to opposite sides of the cell. The sixth phase, Telophase (6), shows the separation of chromosomes into two nuclei, preparing for cell division. Below these phases is Cytokinesis (7), the final stage where the cell membrane pinches and forms two distinct daughter cells. The phases are clearly numbered and illustrated with associated structures like centromeres, chromatin, and spindle fibers.

致谢

当键盘敲下最后一个句点，我知道这段旅程即将抵达终点。回望这四年，图书馆的晨光与实验室的灯火交织成最动人的风景，而在这幅画卷中，最珍贵的莫过于那些温暖的身影。

首先要向我的导师魏老师致以最深的敬意。您总是能在纷繁复杂的学术迷宫中为我点亮明灯，您用言传身教告诉我，学术不仅是知识的积累，更是思维的淬炼与人格的修行。

感谢 2021 级计算机系的同窗们。与你们在代码世界中并肩作战的日子，在自习室互相打气的时光，都将成为我生命中最明亮的印记。特别要感谢室友们，是你们让 324 寝室成为我最温暖的港湾，那些挑灯夜战的期末、分享心事的深夜，构成了青春最动人的和弦。

最后，要将最深沉的爱献给我的家人。父亲沉默的背影，母亲关切的叮咛，是支撑我前行的永恒力量。你们用最朴实的爱教会我：无论飞得多高，家永远是降落时最柔软的草地。

感谢所有途经我生命的人们，你们或深或浅的足迹，共同谱写了这段不可复制的青春诗篇。前路漫漫，这份温暖将永远照亮我前行的方向。

李英骏

2025 年 4 月 25 日

